

統計学 #08

母平均の区間推定・母分散の区間推定

◆第2章 第3節 母平均の区間推定・母分散の区間推定

- ✓ 母数と推定量の違いを理解する
- ✓ 不偏推定量の特徴について理解する

1 : 母数と推定量

■ 推定量

- ✓ 母数を推定するための統計量
- ✓ 確率変数
 - 無作為抽出ごとに、どのデータが抽出されるかは毎回ランダムに変わり、「偶然性を伴う事象」であるため
- ✓ 推定値
 - 推定量に、実際の統計データを代入して計算した値
 - 標本平均 $\bar{X}$ 、標本分散 S^2

■ 母数

- ✓ 母集団の特徴を表す統計量
- ✓ 確率変数ではない（固定値）
 - 母平均 μ 、母分散 σ^2

2：不偏推定量

■ 不偏推定量 unbiased estimator

- ✓ 不偏性 (偏りが無い) をもつ推定量のこと

■ 不偏性 unbiasedness

- ✓ 推定量の不偏性とは「推定量の期待値が、母数と一致する」こと
- ✓ $E(\hat{\theta}) = \theta$
 - θ : 母数
 - $\hat{\theta}$: 母数 θ に対する推定量
- ✓ 標本数 n に依存せずに成り立つ

■ 有効性 `efficiency`

- ✓ 同じ不偏性をもつ推定量同士を比べたとき、分散が小さい推定量の方が良い。

■ 一緻性 `consistency`

- ✓ 標本が大きくなるにつれて、推定量が母数へ収束する。

3：点推定と区間推定

■ 点推定

- ✓ 1つの値をもって、母数を推定する方法
- ✓ $\hat{\theta} = (1 \text{ つの値})$

■ 区間推定

- ✓ 上限値と下限値を推定し、
上限値と下限値の間の区間に
母数が含まれる信頼度を示す方法
- ✓ $(\text{下限値}) \leq \hat{\theta} \leq (\text{上限値})$ 信頼係数 : 95%

4：母平均の点推定量

- 標本平均 $\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$ は母平均 μ の不偏推定量である
(後で示す) . つまり

$$E(\bar{X}) = \mu$$

- そこで標本平均 $\bar{X}$ を母平均の点推定量 $\hat{\mu}$ とする. つまり

$$\hat{\mu} = \bar{X}$$

■, X_1, X_2 : 確率変数, a : 定数 とする.

一般に次が成り立つ.

■ $E(aX) = aE(X), \text{Var}(aX) = a^2 \text{Var}(X)$

■ $E(X_1 + X_2) = E(X_1) + E(X_2)$

■ X_1, X_2 が互いに独立なら

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2)$$

■ 標本平均: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

標本平均の期待値 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$

前ページの公式を用いると上式は次となる.

$$\begin{aligned} E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) &= \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu_x = \frac{1}{n} n \mu_x = \mu_x \end{aligned}$$

つまり

$E(\widehat{\mu}_x) = E(\bar{X}) = \mu_x$ となり, 標本平均は母平均の不偏推定量であることが示された.

5 : 母分散の点推定量

■ 標本分散

- ✓ n 個のデータ（標本）の標本分散 S^2 とは

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

残念なことに標本分散 S^2 の期待値 $E(S^2)$ は母分散 σ^2 に一致しない（後で示す）。

$$E(S^2) \neq \sigma^2$$

■ 標本不偏分散

- ✓ 次式の $\widehat{\sigma^2}$ は母分散 σ^2 の不偏推定量（つまりその期待値が $E(\widehat{\sigma^2}) = \sigma^2$ となる推定量）である（後で示す）。これを標本不偏分散と呼ぶ。

$$\widehat{\sigma^2} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

■ 標本不偏分散 unbiased variance

- ✓ 標本平均 $\bar{x}$ からの偏差二乗和 $\sum (x_i - \bar{x})^2$ を、自由度 $(n - 1)$ で割ったもの

$$\begin{aligned}\widehat{\sigma^2} &= \frac{1}{n-1} \sum (x_i - \bar{x})^2 \\ &= \frac{1}{\text{自由度}} \sum (\text{元のデータ} - \text{標本平均})^2 \\ &= \frac{1}{\text{自由度}} \times (\text{標本平均からの偏差二乗和})\end{aligned}$$

「自由度」の由来は後で説明する.

- 標本平均の分散（確率変数の期待値・母数）

$$Var(\bar{X}) = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

- 標本分散（標本から計算される実現値・統計量）

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- 標本不偏分散（標本から計算される実現値・統計量）

$$\widehat{\sigma^2} = \frac{1}{n-1} \sum (x_i - \bar{x})^2$$

■ 公式を用いて標本平均 $\bar{X}$ の分散（母数）を求める

$$\begin{aligned}\text{■ } \text{Var}(\bar{X}) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \\ &= \frac{1}{n^2} (\sigma_x^2 + \sigma_x^2 + \cdots + \sigma_x^2) = \frac{1}{n^2} n \sigma_x^2 = \frac{1}{n} \sigma_x^2\end{aligned}$$

以上より、標本平均の分散は $\text{Var}(\bar{X}) = \frac{\sigma_x^2}{n}$ であり、データ数 n の増加とともに小となる。つまり標本平均の $\bar{X}$ の実現値 $\bar{x}$ の揺らぎが減り、 $n \rightarrow \infty$ で母平均 μ_x に収束する。

ただしこの「分散」は期待値なので標本を用いた計算では入手できない。

- 公式を用いて標本分散 S^2 (統計量) の期待値 (母数) を求める ($x_i, \bar{x}$ を確率変数 $X_i, \bar{X}$ で置き換える)

$$E(S^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \quad (*)$$

ここで次の式を利用する.

$$\begin{aligned} \sum_{i=1}^n (X_i - \mu_x)^2 &= \sum_{i=1}^n (X_i - \mu_x + \bar{X} - \bar{X})^2 = \sum_{i=1}^n [(X_i - \bar{X}) + (\bar{X} - \mu_x)]^2 \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + 2(\bar{X} - \mu_x) \sum_{i=1}^n (X_i - \bar{X}) + n(\bar{X} - \mu_x)^2 \end{aligned}$$

上式の青の項は $\sum_{i=1}^n (X_i - \bar{X}) = \sum_{i=1}^n X_i - n\bar{X} = n\bar{X} - n\bar{X} = 0$ となるので次を得る.

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu_x)^2 - n(\bar{X} - \mu_x)^2$$

上式を式(*)に代入すると,

$$\begin{aligned} E(S^2) &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= E\left(\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu_x)^2 - n(\bar{X} - \mu_x)^2 \right)\right) \\ &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu_x)^2\right) - E((\bar{X} - \mu_x)^2) \\ &= \frac{1}{n} \sum_{i=1}^n E((X_i - \mu_x)^2) - \text{Var}(\bar{X}) \\ &= \frac{1}{n} \sum_{i=1}^n \sigma_x^2 - \text{Var}(\bar{X}) = \sigma_x^2 - \frac{1}{n} \sigma_x^2 = \frac{n-1}{n} \sigma_x^2 \end{aligned}$$

以上より, 標本分散の期待値は母分散より $\frac{n-1}{n}$ の割合だけ小さい.


■ 「標本分散の期待値が母分散より小さい」理由

母集団から無作為にサンプリングする標本 x_i はサンプリングすることによって μ_x の周りでゆらぐ． 例えばある n 個のデータセット $\{x_i\}$ はたまたま μ_x よりもプラス側（例えば $\mu_x + 1$ ）のごく近くに多く散らばっているとすると、このとき「母平均 μ_x からの分散 $= \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$ 」は大雑把に言って約1になる． このような「データセットのサンプリング」を繰り返した場合（ n 個の標本のサンプリングを m 回繰り返した）の分散の期待値は母分散 σ_x^2 になる．


- 一方, $\mu_x + 1$ の近くに多く散らばっている n 個のデータセット $\{x_i\}$ の標本分散とは, 「**標本平均 $\bar{x}$ を中心**とした散らばりの大きさ」をあらわすが, $\bar{x}$ そのものがおおよそ $\mu_x + 1$ であり, そこからの分散は 1 より小さい. いわばそのデータセットの揺らぎの傾向に寄り添うようにデータの散らばりの評価の中心 $\bar{x}$ を移動させている. よってそのような標本分散の期待値は σ_x^2 よりも小さくなる ($\frac{1}{n}\sigma_x^2$ だけ小さい) .

その**減少幅**は揺らぎの評価の**中心とする標本平均 $\bar{x}$** がどれくらい μ_x から離れてそのデータセットに寄り添っているのかによって決まり, ちょうど「**標本平均 $\bar{x}$ の揺らぎの大きさ (寄り添い幅)**」である $\bar{x}$ の分散 $\frac{1}{n}\sigma_x^2$ となる.

直観的な理解は次のページの図を参照



各データセットにおいては紫の点（標本平均）が散らばりの評価の中心
各データセットごとの標本分散は全データの分散 σ_x^2 より小



全データに対しては赤点 μ_x が散らばりの評価の中心
全データの分散はほぼ σ_x^2

■ 標本分散 S^2 (統計量) の期待値 (母数) は

$$E(S^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma_x^2$$

であった。そこでこれを修正して σ_x^2 にしたい。そのためには、

$$\begin{aligned} \sigma_x^2 &= \frac{n}{n-1} E(S^2) = \frac{n}{n-1} E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) \end{aligned}$$

とすればよい。つまり統計量として右辺の期待値計算の中身

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \widehat{\sigma_x^2}$$

を統計量として用いればよい。これは標本不偏分散である。

■ 標本不偏分散

$$\widehat{\sigma^2} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

は標本平均 $\bar{x}$ からの偏差二乗和 $\sum (x_i - \bar{x})^2$ を $n-1$ で割ったものであった。もし **ゆらぎの評価の中心** $\bar{x}$ が標本とは**独立の値**（例えば μ_x ）であれば、 $\sum (x_i - \mu_x)^2$ の値は標本 x_i を変数とみて、それぞれ独立に任意の値を与えて計算できる。その場合の任意に値を与えてよい変数の数は標本の数 n である。

一方、 $\sum (x_i - \bar{x})^2$ の場合、標本を採取しゆらぎの評価の中心 $\bar{x}$ がある値に定まったとき、それを**定数とみなす**と $\sum (x_i - \bar{x})^2$ の値は標本 x_i をそれぞれ独立に任意の値を与えて計算できない。なぜなら n 個の標本は**定数とみなした** $\bar{x}$ を用いて次の拘束式を満たす必要があるからである。

$$\frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

これにより $n-1$ 個の x_i の値を与えると、残り1個の x_i の値は自動的に定まる。よって上式において自由に選べる x_i の個数は $n-1$ である。これを自由度と呼ぶことにする。

◆第2章 第3節 母平均の区間推定・母分散の区間推定

- ✓ 母数と推定量の違いを理解する
 - 母数: 母集団の特徴を表す統計量・固定値
 - 推定量: 母数を推定するための統計量・確率変数
- ✓ 不偏推定量の特徴について理解する
 - 偏りのない推定量