

統計学 #06

確率分布：連続確率分布 後半


◆第2章 第2節 確率分布

標本と標本平均の性質・中心極限定理

t分布とその特徴について理解する

カイ二乗分布とその特徴について理解する

1 : 連続確率分布 標本



■ 推測統計学 inferential statistics

母集団からランダムに抽出した**標本**を利用して、**母集団の未知の特性値**（平均値や分散など）を**推測**していく方法

❓ 母集団すべてに調査を行い、データを取得することが難しいため

- 標本: X_i 母集団から無作為に抽出されたデータ
 $\{X_1, X_2, \dots, X_n\}$: 標本集合
- 標本平均: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ (標本データの算術平均)
- 偏差二乗和: $\sum_{i=1}^n (X_i - \bar{X}_n)^2$
- 標本分散:
 n 個のデータ (標本) の標本分散 S^2 とは

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

■ 中心極限定理 central limit theorem

母集団は母数の母平均 μ , 母分散 σ^2 の分布とする

その母集団から無作為に n 個の標本を得る

その標本の**標本平均**と**母平均の誤差**の確率分布が,
標本の大きさ n を大きくすると, 期待値0の正規分布に近づく
より具体的には

$$\bar{X}_n - \mu \sim N\left(0, \frac{\sigma^2}{n}\right) \quad \text{あるいは同値で} \quad \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

■ (参考) 大数の法則

試行回数 n を増やすと標本平均の分散 $\frac{\sigma^2}{n}$ は0に近づく

よって標本平均が母平均に収束する

標本平均が母平均の良い推定量であることを示す

母集団は正規分布に従うものとする.

つまり母平均 μ , 母分散 σ^2 の正規分布

その母集団から無作為に n 個の標本を得る

その標本の標本平均は正規分布になる

(近似ではなく任意の n の場合で厳密に正規分布になる)

具体的には

$$\bar{X}_n - \mu = N\left(0, \frac{\sigma^2}{n}\right) \quad \text{あるいは同値で} \quad \bar{X}_n = N\left(\mu, \frac{\sigma^2}{n}\right)$$

1 : 連続確率分布 t分布

- 母集団は正規分布とする→ 標本平均も正規分布
- 標準正規分布に従う確率変数 Z に変換する（標準化）

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{母分散}}{\text{標本数}}}}$$

母平均 μ と母分散 σ^2 が既知なら Z が計算できる

- 母分散 σ^2 が未知の場合

母分散 σ^2 の代わりに**標本不偏分散 $\hat{\sigma}^2$** を使って標準化する

$$T = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\frac{\hat{\sigma}^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{標本不偏分散}}{\text{標本数}}}}$$

確率変数 T は標準正規分布ではなく、**t分布**に従う $T \sim t(\nu)$

- 自由度 degree of freedom

自由に動くことができる変数の数

n 個の変数が満たす等式の数 k とする

その場合の自由度は $\nu = (n - k)$

- 例

4つのデータ : $\{X_1, X_2, X_3, X_4\}$

これらの平均値が 2 だとわかっているとする

$$\text{つまり } \bar{X} = \frac{(x_1 + x_2 + x_3 + x_4)}{4} = 2$$

このときデータ $\{X_1, X_2, X_3, X_4\}$ の自由度は $(4 - 1) = 3$

つまり3個のデータの値が決定すれば残り1個のデータの値も決定する. つまり自由度は3

■ 標本不偏分散 unbiased variance

標本平均 $\bar{X}$ である n 個の標本データ $\{X_i\}$ を考える. データは標本平均が $\bar{X}$ となる等式1個を満たす必要があるので自由度は $(n - 1)$.

その $\bar{X}$ を用いた偏差二乗和 $\sum (X_i - \bar{X})^2$ も自由度 $(n - 1)$

標本不偏分散とは, 偏差二乗和 $\sum (X_i - \bar{X})^2$ を自由度 $(n - 1)$ で割ったもの. つまり

$$\begin{aligned}\hat{\sigma}^2 &= \frac{1}{n-1} \sum (X_i - \bar{X})^2 = \frac{1}{\text{自由度}} \sum (\text{元のデータ} - \text{標本平均})^2 \\ &= \frac{1}{\text{自由度}} \times \text{偏差二乗和}\end{aligned}$$

期待値 $E(\hat{\sigma}^2) = \sigma^2$ ←これ重要！ 次回詳しく説明する

■ t分布 Student's t-distribution

母分散が未知の場合の、母平均に対する標本平均の、標準化された距離を表す分布

❓ 標準化された距離：母分散 σ^2 の代わりに、**標本不偏分散 s^2** を利用して標準化する
自由度によって形状が変わる

自由度が大きくなるほど、標準正規分布に近似する

■ 確率密度関数

$$f(t) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{t^2}{\nu}\right) \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$


■ 期待値

$$E(t) = 0$$

■ 分散

$$\text{Var}(t) = \frac{\nu}{\nu-2} \quad \text{for } \nu > 2$$

$$\text{Var}(t) = \infty \quad \text{for } 1 < \nu \leq 2$$




■ t分布の形状

左右対称

自由度 $\nu = n - 1$ によって形状が変わる

自由度が大きくなるほど、標準正規分布に近似する




2 : 連続確率分布

t分布表の読み方

■ t分布表

確率変数 T の, 上側確率 α に対応する
パーセント点 $t_\alpha(\nu)$ (横軸の値) を表にしたもの

pp.203参照




	標準正規分布表	t分布表
表側	0.0	自由度 ν
表頭	0.00	上側確率 α
表中	上側確率 α	パーセント点 $t_{\alpha}(\nu)$

- 例1) 自由度 $\nu = 20$, 上側確率 $\Pr(T > t) = 0.025$ のときのパーセント点 $t_{0.025}(20)$ を求めたい

手順① 表側から, 自由度20を探す

手順② 表頭から, 上側確率0.025を探す

手順③ 表側と表頭が交差した値2.0860が求めたい上側確率



(補足 1) t分布表の読み方①

18

- 例1) 自由度 $\nu = 20$, 上側確率 $\Pr(T > t) = 0.025$ のときのパーセント点 $t_{0.025}(20)$ を求めたい

手順① 表側から, 自由度20を探す

手順② 表頭から, 上側確率0.025を探す

手順③ 表側と表頭が交差した値2.0860が求めたい上側確率

t分布表

ν	0.250	0.200	0.100	0.050	0.025	0.010	0.005	0.0005
1	1.00000	1.37638	3.07768	6.31375	12.70620	31.82052	63.65674	636.6192
2	0.81650	1.06066	1.88562	2.91999	4.30265	6.96456	9.92484	31.59905
3	0.76489	0.97847	1.63774	2.35336	3.18245	4.54070	5.84091	12.92398
4	0.74070	0.94096	1.53321	2.13185	2.77645	3.74695	4.60409	8.61030
5	0.72669	0.91954	1.47588	2.01505	2.57058	3.36493	4.03214	6.86883
6	0.71756	0.90570	1.43976	1.94318	2.44691	3.14267	3.70743	5.95882
7	0.71114	0.89603	1.41492	1.89458	2.36462	2.99795	3.49948	5.40788
8	0.70639	0.88889	1.39682	1.85955	2.30600	2.89646	3.35539	5.04131
9	0.70272	0.88340	1.38303	1.83311	2.26216	2.82144	3.24984	4.78091
10	0.69981	0.87906	1.37218	1.81246	2.22814	2.76377	3.16927	4.58689
11	0.69745	0.87553	1.36343	1.79588	2.20099	2.71808	3.10581	4.43698
12	0.69548	0.87261	1.35622	1.78229	2.17881	2.68100	3.05454	4.31779
13	0.69383	0.87015	1.35017	1.77093	2.16037	2.65031	3.01228	4.22083
14	0.69242	0.86805	1.34503	1.76131	2.14479	2.62449	2.97684	4.14045
15	0.69120	0.86624	1.34061	1.75305	2.13145	2.60248	2.94671	4.07277
16	0.69013	0.86467	1.33676	1.74588	2.11991	2.58349	2.92078	4.01500
17	0.68920	0.86328	1.33338	1.73961	2.10982	2.56693	2.89823	3.96513
18	0.68836	0.86205	1.33039	1.73406	2.10092	2.55238	2.87844	3.92165
19	0.68762	0.86095	1.32773	1.72913	2.09302	2.53948	2.86093	3.88341
20	0.68695	0.85996	1.32534	1.72472	2.08596	2.52798	2.84534	3.84952

(補足2) t分布表の読み方①

19

- 例1) 自由度 $\nu = 20$, 上側確率 $\Pr(T > t) = 0.025$ のときのパーセント点 $t_{0.025}(20)$ を求めたい

手順① 表側から, 自由度20を探す

手順② 表頭から, 上側確率0.025を探す

手順③ 表側と表頭が交差した値2.0860が求めたい上側確率

t分布表

ν	0.250	0.200	0.100	0.050	0.025	0.010	0.005	0.0005
1	1.00000	1.37638	3.07768	6.31375	12.70620	31.82052	63.65674	636.6192
2	0.81650	1.06066	1.88562	2.91999	4.30265	6.96456	9.92484	31.59905
3	0.76489	0.97847	1.63774	2.35336	3.18245	4.54070	5.84091	12.92398
4	0.74070	0.94096	1.53321	2.13185	2.77645	3.74695	4.60409	8.61030
5	0.72669	0.91954	1.47588	2.01505	2.57058	3.36493	4.03214	6.86883
6	0.71756	0.90570	1.43976	1.94318	2.44691	3.14267	3.70743	5.95882
7	0.71114	0.89603	1.41492	1.89458	2.36462	2.99795	3.49948	5.40788
8	0.70639	0.88889	1.39682	1.85955	2.30600	2.89646	3.35539	5.04131
9	0.70272	0.88340	1.38303	1.83311	2.26216	2.82144	3.24984	4.78091
10	0.69981	0.87906	1.37218	1.81246	2.22814	2.76377	3.16927	4.58689
11	0.69745	0.87553	1.36343	1.79588	2.20099	2.71808	3.10581	4.43698
12	0.69548	0.87261	1.35622	1.78229	2.17881	2.68100	3.05454	4.31779
13	0.69383	0.87015	1.35017	1.77093	2.16037	2.65031	3.01228	4.22083
14	0.69242	0.86805	1.34503	1.76131	2.14479	2.62449	2.97684	4.14045
15	0.69120	0.86624	1.34061	1.75305	2.13145	2.60248	2.94671	4.07277
16	0.69013	0.86467	1.33676	1.74588	2.11991	2.58349	2.92078	4.01500
17	0.68920	0.86328	1.33338	1.73961	2.10982	2.56693	2.89823	3.96513
18	0.68836	0.86205	1.33039	1.73406	2.10092	2.55238	2.87844	3.92165
19	0.68762	0.86095	1.32773	1.72913	2.09302	2.53948	2.86093	3.88341
20	0.68695	0.85996	1.32534	1.72472	2.08596	2.52798	2.84534	3.84952

■ 例2) 自由度 $\nu = 10$ のとき, $\Pr(-t_a(10) < T < t_a(10)) = 0.90$ となるパーセント点 $t_a(10)$ を求めたい


✓ 手順① 確率の合計は1なので, 両端の確率の合計は0.1

➤ $1 - 0.90 = 0.10$

✓ 手順② t分布は左右対称なので, 左端と右端の面積は等しい

➤ 上側確率 $\alpha = \frac{1}{2} \times 0.1 = 0.05$

✓ 手順③ パーセント点 $t_{0.05}(10)$ を表から読み取る



- 例2) 自由度 $\nu = 10$ のとき, $\Pr(-t_a(10) < T < t_a(10)) = 0.90$ となるパーセント点 $t_a(10)$ を求めたい


手順① 確率の合計は1なので, 両端の確率の合計は0.1

❓ $1 - 0.90 = 0.10$

手順② t分布は左右対称なので, 左端と右端の面積は等しい

❓ 上側確率 $\alpha = \frac{1}{2} \times 0.1 = 0.05$

手順③ パーセント点 $t_{0.05}(10)$ を表から読み取る



3 : 連続確率分布

カイ二乗分布


■ カイ二乗分布 chi-squared distribution

独立に標準正規分布に従う確率変数 X の平方和を表す分布

$$U \sim \chi^2(\nu)$$

$$U = \frac{\sum (x_i - \mu)^2}{\sigma^2} = \frac{\sum (x_i - \bar{X})^2}{\sigma^2} + \frac{n(\bar{X} - \mu)^2}{\sigma^2}$$

左右非対称. 自由度が大きくなるほど, 左右対称になっていく



◆第2章 第2節 確率分布

標本と標本平均の性質・中心極限定理

t分布とその特徴について理解する

❏ 自由度が大きくなると，標準正規分布に近似する

カイ二乗分布とその特徴について理解する

❏ 左右非対称，自由度が大きくなると左右対称に近づく