

統計学 #08

母平均の区間推定・母分散の区間推定 前半

◆第2章 第3節 母平均の区間推定・母分散の区間推定

- ✓ 母数と推定量の違いを理解する
- ✓ 不偏推定量の特徴について理解する

1 : 母数と推定量

■ 推定量

- ✓ 母数を推定するための統計量
- ✓ 確率変数
 - 無作為抽出ごとに、どのデータが抽出されるかは毎回ランダムに変わり、「偶然性を伴う事象」であるため
- ✓ 推定値
 - 推定量に実際の統計データを代入して計算した値
 - 標本平均 $\bar{X}$ の実現値 $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$,
 - 標本分散 S^2 の実現値 $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$

■ 母数

- ✓ 母集団の特徴を表す統計量
- ✓ 確率変数ではない（固定値）
 - 母平均 μ , 母分散 σ^2

2 : 不偏推定量

■ 不偏推定量 unbiased estimator

- ✓ 不偏性 (偏りが無い) をもつ推定量のこと

■ 不偏性 unbiasedness

- ✓ 推定量の不偏性とは「推定量の期待値が、母数と一致する」こと
- ✓ $E(\hat{\theta}) = \theta$
 - θ : 母数
 - $\hat{\theta}$: 母数 θ に対する推定量
- ✓ 標本数 n に依存せずに成り立つ

■ 有効性 efficiency

- ✓ 同じ不偏性をもつ推定量同士を比べたとき、分散が小さい推定量の方が良い。

■ 一貫性 consistency

- ✓ 標本が大きくなるにつれて、推定量が母数へ収束する。

3 : 点推定と区間推定

■ 点推定

- ✓ 1つの値をもって，母数を推定する方法
- ✓ $\hat{\theta} = (\text{1つの値})$

■ 区間推定

- ✓ 上限値と下限値を推定し，
上限値と下限値の間の区間に
母数が含まれる信頼度を示す方法
- ✓ $(\text{下限値}) \leq \hat{\theta} \leq (\text{上限値})$ 信頼係数：95%

4 : 母平均の点推定量

- 標本平均 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ は母平均 μ の不偏推定量である
(後で示す) . つまり

$$E(\bar{X}) = \mu$$

- そこで標本平均 $\bar{X}$ を母平均の点推定量 $\hat{\mu}$ とする. つまり

$$\hat{\mu} = \bar{X}$$

X, X_1, X_2 : 確率変数, a : 定数 とする.

一般に次が成り立つ.

- $E(aX) = aE(X), \text{Var}(aX) = a^2\text{Var}(X)$

- $E(X_1 + X_2) = E(X_1) + E(X_2)$

- X_1, X_2 が互いに独立なら

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2)$$

(ADVANCED) 標本平均は母平均の不偏推定量であることの理由

13

$$\text{標本平均: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{標本平均の期待値 } E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

前ページの公式を用いると上式は次となる.

$$\begin{aligned} E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) &= \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu_x = \frac{1}{n} n \mu_x = \mu_x \end{aligned}$$

つまり

$E(\hat{\mu}_x) = E(\bar{X}) = \mu_x$ となり, 標本平均は母平均の**不偏推定量**であることが示された.

5 : 母分散の点推定量

■ 標本分散

✓ n 個のデータ（標本）の標本分散 S^2 とは

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

残念なことに標本分散 S^2 の期待値 $E(S^2)$ は母分散 σ^2 に一致しない（後で示す）。

$$E(S^2) \neq \sigma^2$$

■ 標本不偏分散

✓ 次式の $\hat{\sigma}^2$ は母分散 σ^2 の不偏推定量（つまりその期待値が $E(\hat{\sigma}^2) = \sigma^2$ となる推定量）である（後で示す）。これを標本不偏分散と呼ぶ。

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

■ 標本不偏分散 unbiased variance

標本平均 $\bar{X}$ である n 個の標本データ $\{X_i\}$ を考える. データは標本平均が $\bar{X}$ となる等式1個を満たす必要があるので自由度は $(n - 1)$.

その $\bar{X}$ を用いた偏差二乗和 $\sum (X_i - \bar{X})^2$ も自由度 $(n - 1)$

標本不偏分散とは, 偏差二乗和 $\sum (X_i - \bar{X})^2$ を自由度 $(n - 1)$ で割ったもの. つまり

$$\begin{aligned}\hat{\sigma}^2 &= \frac{1}{n-1} \sum (X_i - \bar{X})^2 = \frac{1}{\text{自由度}} \sum (\text{元のデータ} - \text{標本平均})^2 \\ &= \frac{1}{\text{自由度}} \times \text{偏差二乗和}\end{aligned}$$

期待値 $E(\hat{\sigma}^2) = \sigma^2 \quad \rightarrow \quad \text{“分散の不偏推定量”}$

- 標本平均の分散（確率変数の期待値・母数）

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

- 標本分散（標本から計算される統計量）

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

- 標本不偏分散（標本から計算される統計量）

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$$

公式を用いて標本平均 $\bar{X}$ の分散（母数）を求める

$$\begin{aligned}\blacksquare \text{Var}(\bar{X}) &= \text{Var}\left(\frac{1}{n}\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2}\text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2}\sum_{i=1}^n \text{Var}(X_i) \\ &= \frac{1}{n^2}(\sigma_x^2 + \sigma_x^2 + \cdots + \sigma_x^2) = \frac{1}{n^2}n\sigma_x^2 = \frac{1}{n}\sigma_x^2\end{aligned}$$

以上より、標本平均の分散は $\text{Var}(\bar{X}) = \frac{\sigma_x^2}{n}$ であり、データ数 n の増加とともに小となる。つまり標本平均の $\bar{X}$ の実現値 $\bar{x}$ の揺らぎが減り、 $n \rightarrow \infty$ で母平均 μ_x に収束する。

ただしこの「分散」は期待値なので標本を用いた計算では入手できない。

公式を用いて標本分散 S^2 (統計量) の期待値 (母数) を求める

$$E(S^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \quad (*)$$

ここで次の式を利用する.

$$\begin{aligned} \sum_{i=1}^n (X_i - \mu_x)^2 &= \sum_{i=1}^n (X_i - \mu_x + \bar{X} - \bar{X})^2 = \sum_{i=1}^n [(X_i - \bar{X}) + (\bar{X} - \mu_x)]^2 \\ &= \sum_{i=1}^n (X_i - \bar{X})^2 + 2(\bar{X} - \mu_x) \sum_{i=1}^n (X_i - \bar{X}) + n(\bar{X} - \mu_x)^2 \end{aligned}$$

上式の青の項は $\sum_{i=1}^n (X_i - \bar{X}) = \sum_{i=1}^n X_i - n\bar{X} = n\bar{X} - n\bar{X} = 0$ となるので次を得る.

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu_x)^2 - n(\bar{X} - \mu_x)^2$$

上式を式(*)に代入すると,

$$\begin{aligned} E(S^2) &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= E\left(\frac{1}{n} \left(\sum_{i=1}^n (X_i - \mu_x)^2 - n(\bar{X} - \mu_x)^2\right)\right) \\ &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu_x)^2\right) - E((\bar{X} - \mu_x)^2) \\ &= \frac{1}{n} \sum_{i=1}^n E((X_i - \mu_x)^2) - \text{Var}(\bar{X}) \\ &= \frac{1}{n} \sum_{i=1}^n \sigma_x^2 - \text{Var}(\bar{X}) = \sigma_x^2 - \frac{1}{n} \sigma_x^2 = \frac{n-1}{n} \sigma_x^2 \end{aligned}$$

以上より, 標本分散の期待値は母分散より $\frac{n-1}{n}$ の割合だけ小さい.

「標本分散の期待値が母分散より小さい」理由

母集団から無作為にサンプリングする標本の実現値 x_i はサンプリングすることによって μ_x の周りでゆらぐ． 例えばある n 個のデータセットの実現値 $\{x_i\}$ はたまたま μ_x よりもプラス側（例えば $\mu_x + 1$ ）のごく近くに多く散らばっているとする． このとき


$$\text{「母平均 } \mu_x \text{ からの分散} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2 \text{」}$$

は大雑把にいて約1になる． このような「データセットのサンプリング」を繰り返した場合（ n 個の標本のサンプリングを m 回繰り返した）の分散の期待値は母分散 σ_x^2 になる．


一方, $\mu_x + 1$ の近くに多く散らばっている n 個のデータセット $\{x_i\}$ の標本分散とは, 「**標本平均(の実現値) $\bar{x}$ を中心**とした散らばりの大きさ」をあらわすが, $\bar{x}$ そのものがおおよそ $\mu_x + 1$ であり, そこからの分散は 1 より小さい. いわばそのデータセットの揺らぎの傾向に寄り添うようにデータの散らばりの評価の中心 $\bar{x}$ を移動させている. よってそのような標本分散の期待値は σ_x^2 よりも小さくなる ($\frac{1}{n} \sigma_x^2$ だけ小さい) .

その**減少幅**は揺らぎの評価の**中心とする標本平均 $\bar{x}$** がどれくらい μ_x から離れてそのデータセットに寄り添っているのかによって決まり, ちょうど「**標本平均 $\bar{x}$ の揺らぎの大きさ (寄り添い幅)**」である $\bar{x}$ の分散 $\frac{1}{n} \sigma_x^2$ となる.

直観的な理解は次のページの図を参照



各データセットにおいては紫の点（標本平均）が散らばりの評価の中心
各データセットごとの標本分散は全データの分散 σ_x^2 より小



全データに対しては赤点 μ_x が散らばりの評価の中心
全データの分散はほぼ σ_x^2

標本分散 S^2 (統計量) の期待値 (母数) は

$$E(S^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma_x^2$$

であった。そこでこれを修正して σ_x^2 にしたい。そのためには、

$$\begin{aligned} \sigma_x^2 &= \frac{n}{n-1} E(S^2) = \frac{n}{n-1} E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) \end{aligned}$$

とすればよい。つまり統計量として右辺の期待値計算の中身

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \hat{\sigma}^2$$

を統計量として用いればよい。これは標本不偏分散である。

標本不偏分散

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

は標本平均 $\bar{X}$ からの偏差二乗和 $\sum (X_i - \bar{X})^2$ を $n-1$ で割ったものであった。もしゆらぎの評価の中心 $\bar{X}$ が標本とは独立の値（例えば μ_x ）であれば、 $\sum (X_i - \mu_x)^2$ の値は標本 X_i を変数とみて、それぞれ独立に任意の値を与えて計算できる。その場合の任意に値を与えてよい変数の数は標本の数 n である。

一方、 $\sum (X_i - \bar{X})^2$ の場合、標本を採取しゆらぎの評価の中心 $\bar{X}$ がある値に定まったとき、それを定数とみなすと $\sum (X_i - \bar{X})^2$ の値は標本 X_i をそれぞれ独立に任意の値を与えて計算できない。なぜなら n 個の標本は定数とみなした $\bar{X}$ を用いて次の拘束式を満たす必要があるからである。

$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

これにより $n-1$ 個の X_i の値を与えると、残り1個の X_i の値は自動的に定まる。よって上式において自由に選べる X_i の個数は $n-1$ である。これを自由度と呼ぶことにする。

◆第2章 第3節 母平均の区間推定・母分散の区間推定

✓ 母数と推定量の違いを理解する

- 母数：母集団の特徴を表す統計量・固定値
- 推定量：母数を推定するための統計量・確率変数

✓ 不偏推定量の特徴について理解する

- 偏りのない推定量

X : 確率変数, $f(x)$: 確率密度関数, $\int f(x)dx = 1$

$$E[X] = \int x f(x)dx = \mu_x$$

$$\begin{aligned} V[X] &= \int (x - \mu_x)^2 f(x)dx = \int (x^2 - 2x\mu_x + \mu_x^2) f(x)dx \\ &= \int x^2 f(x)dx - \int 2x\mu_x f(x)dx + \int \mu_x^2 f(x)dx \\ &= E[X^2] - 2\mu_x \int x f(x)dx + \mu_x^2 \int f(x)dx = E[X^2] - 2\mu_x^2 + \mu_x^2 \\ &= E[X^2] - \mu_x^2 \\ &= E[X^2] - (E[X])^2 =: \sigma_x^2 \end{aligned}$$

a : 定数

$$E[aX] = \int ax f(x)dx = a \int x f(x)dx = aE[X] = a\mu_x$$

$$\begin{aligned} V[aX] &= E[(aX)^2] - (E[aX])^2 = E[a^2 X^2] - (aE[X])^2 \\ &= a^2 E[X^2] - a^2 (E[X])^2 = a^2 (E[X^2] - (E[X])^2) = a^2 \sigma_x^2 \end{aligned}$$

2変数の場合

$$X = X_1 + X_2, f_1(x_1), f_2(x_2), \int f_1(x_1)dx_1 = 1, \int f_2(x_2)dx_2 = 1$$

$f(x) = f(x_1, x_2)$: 同時確率密度関数

$\int f(x_1, x_2)dx_2 = f_1(x_1)$: x_1 の周辺確率密度関数

$\int f(x_1, x_2)dx_1 = f_2(x_2)$: x_2 の周辺確率密度関数

$$\int \int f(x_1, x_2)dx_1dx_2 = \int \left(\int f(x_1, x_2)dx_1 \right) dx_2 = \int f_2(x_2)dx_2 = 1$$

$$\begin{aligned} E[X] &= E[X_1 + X_2] = \int \int (x_1 + x_2) f(x_1, x_2)dx_1dx_2 \\ &= \int \int x_1 f(x_1, x_2)dx_1dx_2 + \int \int x_2 f(x_1, x_2)dx_1dx_2 \\ &= \int \left(\int x_1 f(x_1, x_2)dx_2 \right) dx_1 + \int \left(\int x_2 f(x_1, x_2)dx_1 \right) dx_2 \\ &= \int x_1 \left(\int f(x_1, x_2)dx_2 \right) dx_1 + \int x_2 \left(\int f(x_1, x_2)dx_1 \right) dx_2 \\ &= \int x_1 f_1(x_1)dx_1 + \int x_2 f_2(x_2)dx_2 = E[X_1] + E[X_2] \end{aligned}$$

2変数の場合

$$\begin{aligned} V[X] &= V[X_1 + X_2] = E[(X_1 + X_2)^2] - (E[X_1 + X_2])^2 \\ &= E[X_1^2] + E[2X_1X_2] + E[X_2^2] - (\mu_{x_1} + \mu_{x_2})^2 \\ &= \int \int x_1^2 f(x_1, x_2) dx_1 dx_2 + \int \int 2x_1 x_2 f(x_1, x_2) dx_1 dx_2 \\ &\quad + \int \int x_2^2 f(x_1, x_2) dx_1 dx_2 - \mu_{x_1}^2 - 2\mu_{x_1}\mu_{x_2} - \mu_{x_2}^2 \\ &= \int x_1^2 f_1(x_1) dx_1 + 2 \int \int x_1 x_2 f(x_1, x_2) dx_1 dx_2 + \int x_2^2 f_2(x_2) dx_2 \\ &\quad - \mu_{x_1}^2 - 2\mu_{x_1}\mu_{x_2} - \mu_{x_2}^2 \\ &= E[X_1^2] + E[X_2^2] + 2 \int \int x_1 x_2 f(x_1, x_2) dx_1 dx_2 \\ &\quad - \mu_{x_1}^2 - 2\mu_{x_1}\mu_{x_2} - \mu_{x_2}^2 \end{aligned} \quad \text{式(1)}$$

X_1, X_2 が独立の場合

$$f(x_1, x_2) = f_1(x_1) \cdot f_2(x_2)$$

よって

$$\begin{aligned} \int \int x_1 x_2 f(x_1, x_2) dx_1 dx_2 &= \int \int x_1 x_2 f_1(x_1) \cdot f_2(x_2) dx_1 dx_2 \\ &= \int \left(\int x_1 f_1(x_1) \cdot x_2 f_2(x_2) dx_1 \right) dx_2 \\ &= \int \left(\int x_1 f_1(x_1) dx_1 \right) x_2 f_2(x_2) dx_2 = \int \mu_{x_1} x_2 f_2(x_2) dx_2 \\ &= \mu_{x_1} \int x_2 f_2(x_2) dx_2 = \mu_{x_1} \cdot \mu_{x_2} \end{aligned}$$

これを式(1)に代入して

$$V[X]$$

$$\begin{aligned} &= E[X_1^2] + E[X_2^2] + 2\mu_{x_1} \cdot \mu_{x_2} - \mu_{x_1}^2 - 2\mu_{x_1}\mu_{x_2} - \mu_{x_2}^2 \\ &= E[X_1^2] + E[X_2^2] - \mu_{x_1}^2 - \mu_{x_2}^2 = (E[X_1^2] - \mu_{x_1}^2) + (E[X_2^2] - \mu_{x_2}^2) \\ &= V[X_1] + V[X_2] = \sigma_{x_1}^2 + \sigma_{x_2}^2 \end{aligned}$$

標準化

$$X, E[X] = \mu_x, V[X] = \sigma_x^2$$

$$Z = \frac{X - E[X]}{\sqrt{V[X]}} \text{ とおく (標準化)}$$

$$E[Z] = E\left[\frac{X - E[X]}{\sqrt{V[X]}}\right] = \frac{1}{\sqrt{V[X]}} E[X - E[X]]$$

$$= \frac{1}{\sqrt{V[X]}} (E[X] - E[E[X]]) = \frac{1}{\sqrt{V[X]}} (\mu_x - E[\mu_x])$$

$$= \frac{1}{\sqrt{V[X]}} (\mu_x - \mu_x) = 0$$

$$\begin{aligned} V[Z] &= V\left[\frac{X - E[X]}{\sqrt{V[X]}}\right] = \frac{1}{\sqrt{V[X]}} V[X - E[X]] \\ &= \frac{1}{\sqrt{V[X]}} \left(E[(X - E[X])^2] - (E[X - E[X]])^2 \right) \\ &= \frac{1}{\sqrt{V[X]}} E[(X - E[X])^2] - \frac{(E[X - E[X]])^2}{\sqrt{V[X]}} \\ &= \frac{\sqrt{V[X]}}{\sqrt{V[X]}} - \frac{(E[X] - E[X])^2}{\sqrt{V[X]}} = \frac{\sqrt{V[X]}}{\sqrt{V[X]}} = 1 \end{aligned}$$

標本平均の標準化

$$\bar{X}: \text{標本平均}, \quad E[\bar{X}] = \mu_x, \quad V[\bar{X}] = \frac{1}{n} \sigma_x^2$$

$$Z = \frac{\bar{X} - E[\bar{X}]}{\sqrt{V[\bar{X}]}} = \frac{\bar{X} - \mu_x}{\sqrt{\frac{\sigma_x^2}{n}}} \quad \text{標準化}$$