

統計学 #13

回帰分析とその他の代表的な分析手法 / 回帰分析の結果の解釈 後半

◆第3章 第5節 分析結果の誤った解釈

- ✓ 分析結果の誤った解釈の事例を理解する

CH3-5 : 分析結果の誤った解釈

■ ✓ (pp. 189)

記述統計量は表1の通りである.

表1より, 体重のほうが**分散の値が小さく**,
身長に比べてデータの**ばらつきは小さい**ことがわかる.

- 単位の違うデータ同士で, ばらつきを比較したい場合は,
変動係数coefficient of variationを利用する

$$CV = \frac{\sigma}{\mu} = \frac{\text{標準偏差}}{\text{平均値}}$$

✓ (pp. 190)

説明変数として使用した人口の推定係数は統計的に有意とはならず、目的変数である GDP と説明変数である人口は、**因果関係がない**ことが明らかになった。

- 推定係数（推定した回帰係数）が有意でない場合，
「統計的に因果関係があるかどうか**わからない**」だけで，
「**因果関係がない**」とはいえない。

- ✓ (pp. 191)
人口の増加がCO₂排出量に与える影響を見るために、以下の式を用いて回帰分析を行った。
 - ✓ $(人口_i) = a + b(CO2_i) + \varepsilon_i$
 - ✓ 推定結果より、 $b = 0.35$ となり、有意水準5%で統計的に有意な結果を得た。ここから、人口が1単位増加すると、CO₂排出量が0.35単位増加することが明らかになった。
- 説明変数（原因，右辺）が1単位増加すると、
目的変数（結果，左辺）が **b** 単位増加する，と読む。
- 因果関係は「原因→結果」の一方通行
 - ✓ 例文の推定式から読めることは
「CO₂排出量が1単位増えると、人口が **b** 単位増える」…？

④自由度修正済み決定係数がマイナス値

7

✓ (pp. 192)

自由度修正済み決定係数の値は－ 0.0012 であり、
モデルの当てはまりは非常に悪い。

- 説明変数の個数が多い（自由度が小さい）が、説明力（目的変数との関係性が薄い）場合。
- 「モデルの当てはまりは悪い」とする読み方は誤りではないが、分析モデルや変数選択、データの特徴を見直した方が良い。

✓ (pp. 193)

サッカーの試合の勝敗 (勝ち = 1, それ以外 = 0) に影響を与える要因を明らかにするため、**最小二乗法**を用いて分析を行う。

- 目的変数がダミー変数である場合は、最小二乗法の前提条件を満たさないため、他の方法 (ロジット, プロビットなど) を用いることを検討する。
- 分析目的や使用データに**適した分析方法**を選択する。

■ 最小二乗法の推定量が不偏性をもつ条件

- ✓ ①説明変数 x_i が確率変数ではない
- ✓ ②標本数 n が大きくなるとき、偏差平方和は無限大になる
- ✓ ③誤差項の期待値は0である
 - $E(u_i) = 0$
- ✓ ④誤差項の分散は一定である（均一分散性）
 - $Var(u_i) = \sigma^2$
- ✓ ⑤誤差項は互いに無相関である（独立性）
 - $Cov(u_i, u_j) = 0, i \neq j$

■ これらの条件を満たすモデルを古典的回帰モデルという

- ✓ 古典的回帰モデルで推定された推定量は最良である
 - ガウス・マルコフ定理

- ✓ (pp. 195)
- ✓ 高血圧の人ほど年収が高い.
- ✓ アイスの売上が上がるほど、熱中症患者が増える.
- ✓ 少子化が進むと、温暖化が進む

- 相関係数の絶対値が大きいかからといって、因果関係があるとはいえない.
- **相関関係と因果関係は別物**であることに注意.
 - ✓ 相関関係：関係性がある
 - ✓ 因果関係：原因と結果の関係

✓ (pp. 196)

集落 A には 30 戸の農家がある.

集落 A にある農家の年収について調査を行うため,
30 戸すべての農家に年収に関する調査を行って回答を得た.

このサンプルサイズ 30 のデータを用いて,
年収の平均値に関する区間推定を行う.

■ 母集団のデータが手元にあるならば,
そもそも推定作業は不要.

✓ 推定: 母集団の特徴が未知のとき,
標本のデータから母集団を推測していく方法.

◆第3章 第5節 分析結果の誤った解釈

- ✓ 分析結果の誤った解釈の事例を理解する