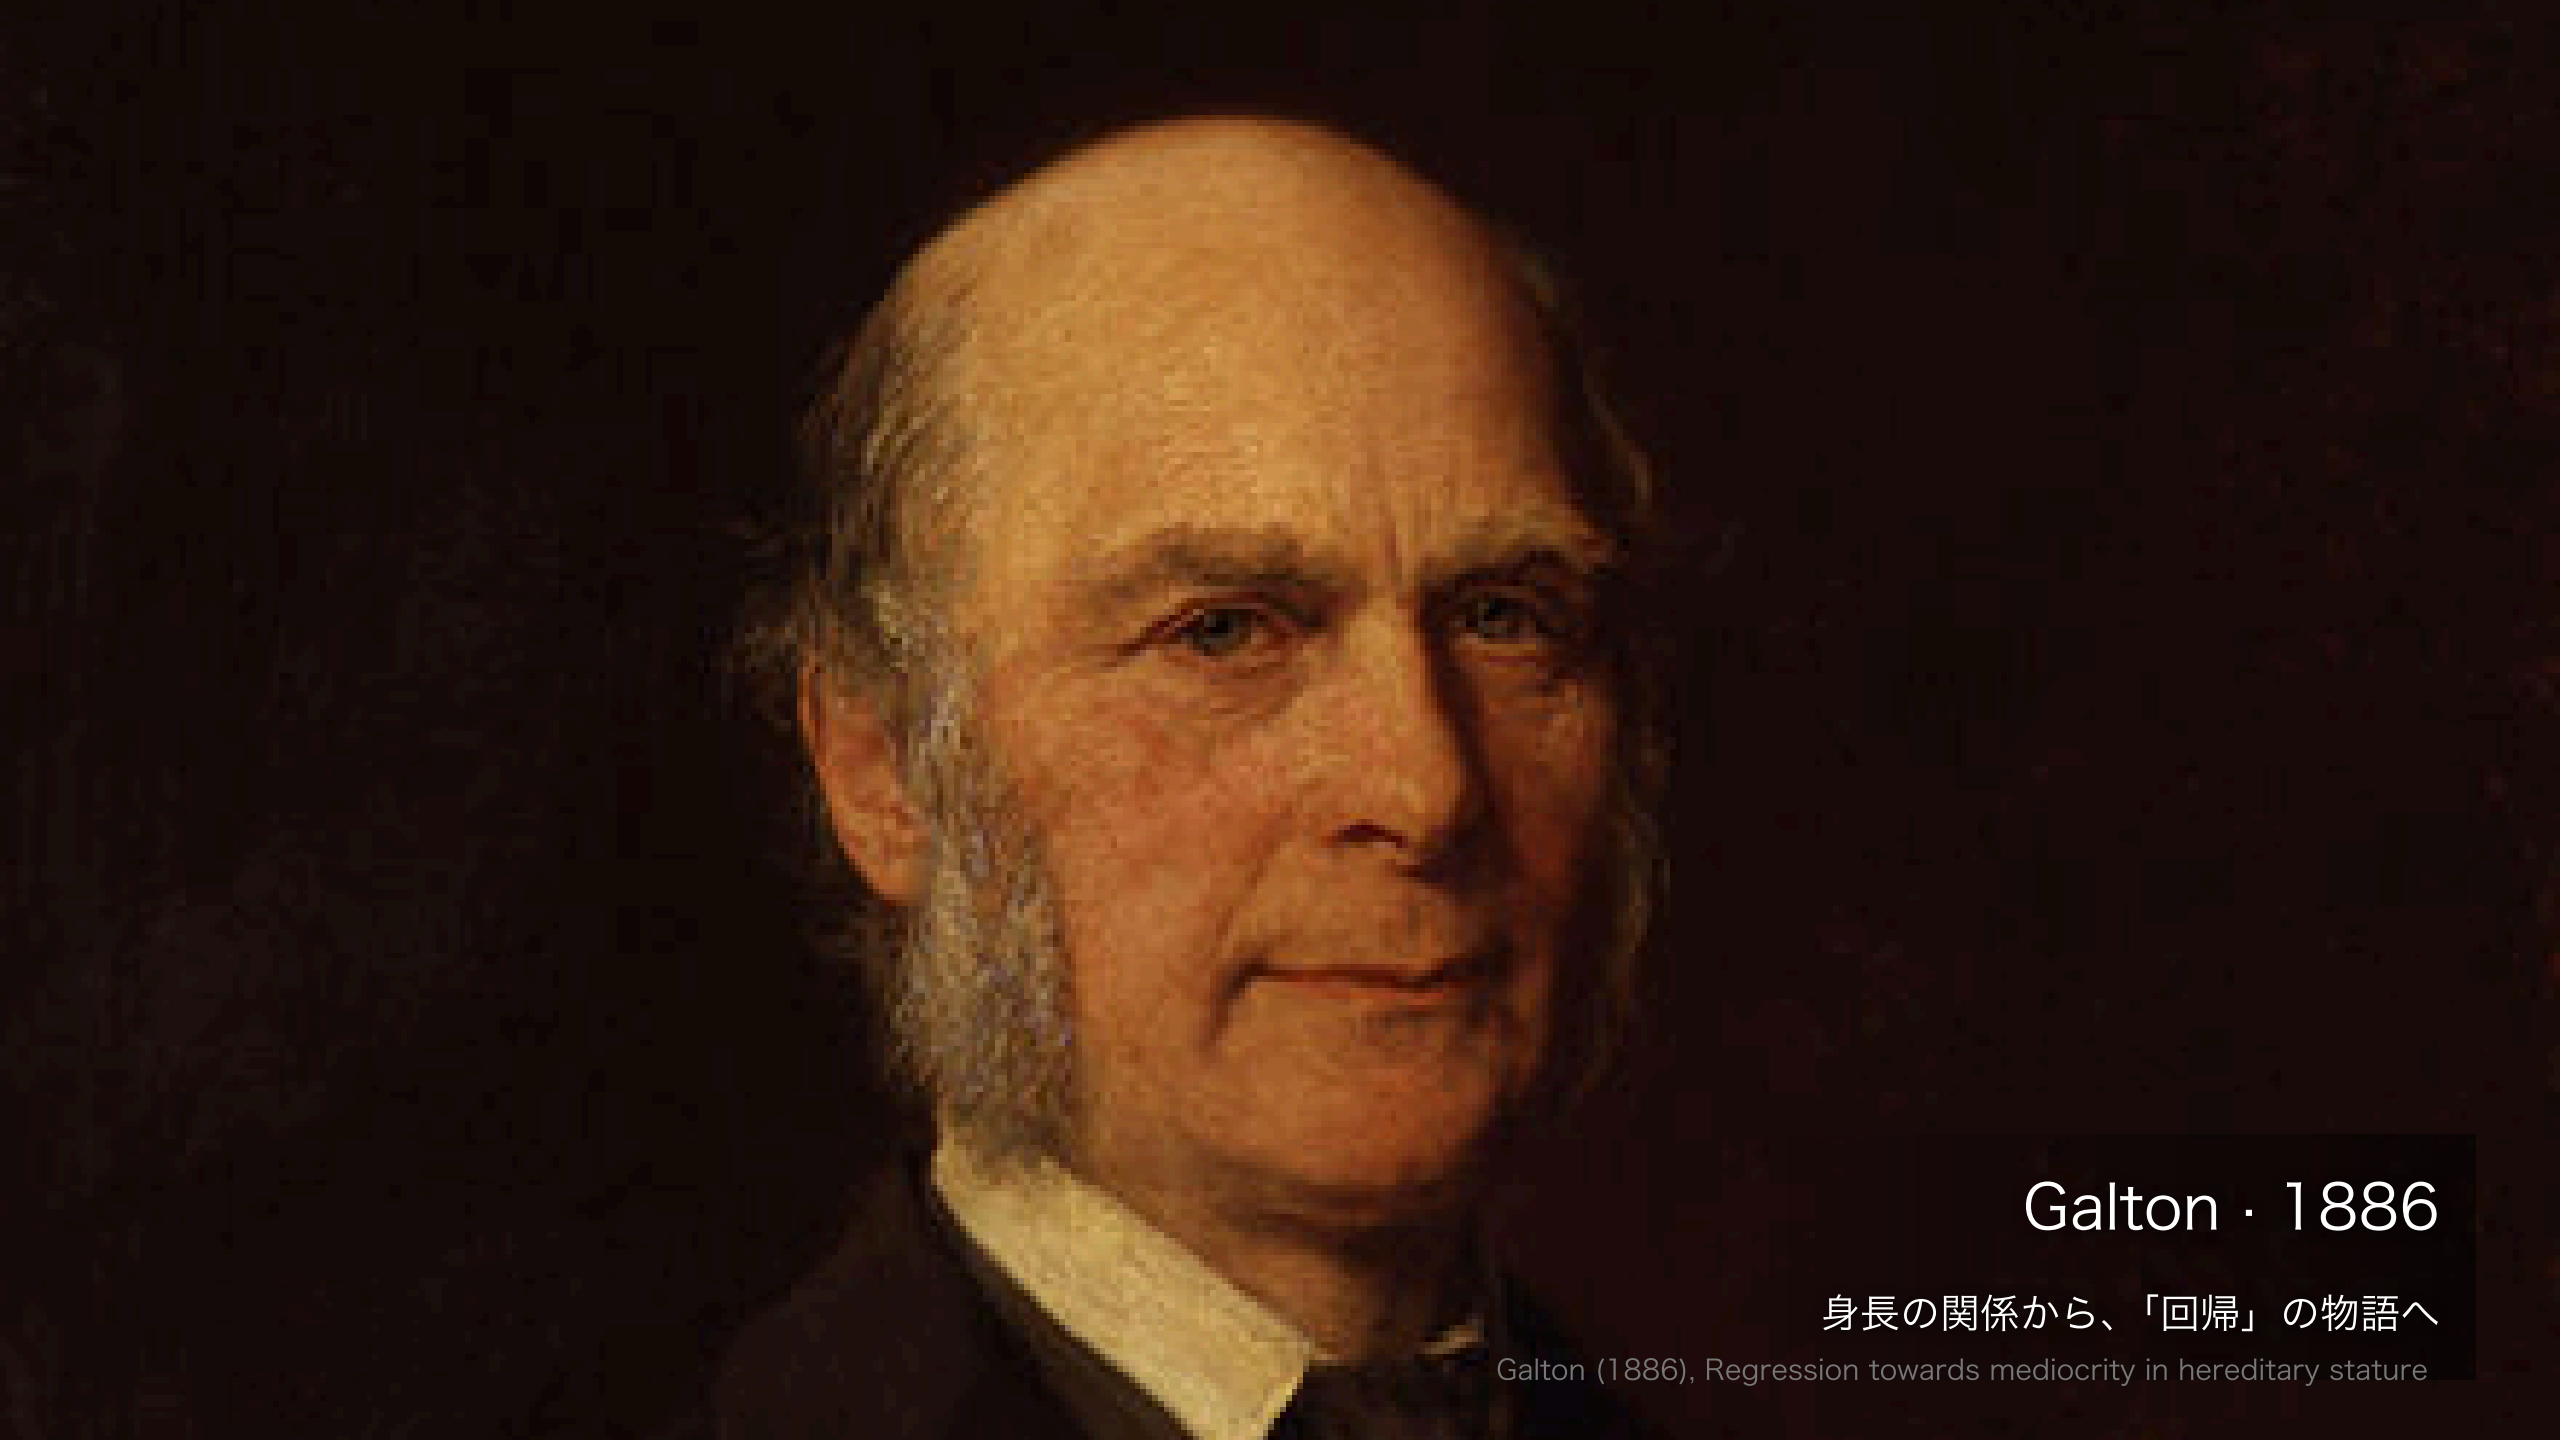


Galton · 1886

身長の関係から、「回帰」の物語へ

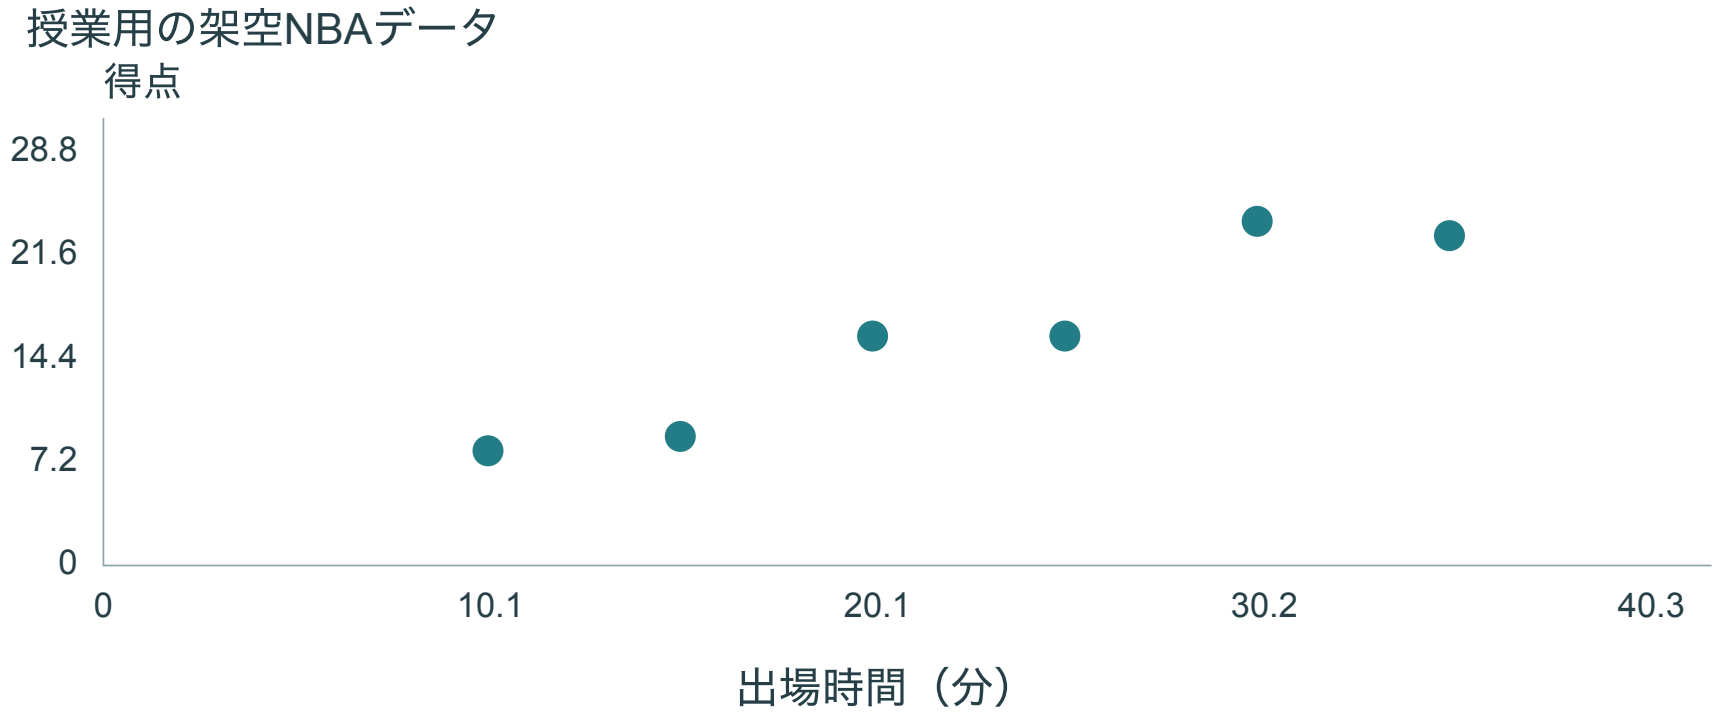
Galton (1886), Regression towards mediocrity in hereditary stature

出場時間が長いと、得点も多い？

どちらを横軸にする？

どちらを縦軸にする？

点で見ると、関係が見えてくる



1点＝1試合。授業用の架空NBAデータ。

関係がある、から、原因だとは言えない

よく得点する選手だから、長く出場するかもしれない。

相手、戦術、役割なども違う。

散布図だけで、因果関係は確定しない。

教科書 p.71

回帰分析

Regression analysis

xとyに、名前を付ける

x：説明変数 → 出場時間（分）。

y：目的変数 → 得点。

知りたい方向を、先に決める。

教科書 p.71

二つの変数を、直線で関係づける

$$y_i = a + bx_i + u_i$$

教科書 p.71（回帰分析）

a、b、uは、何を表す？

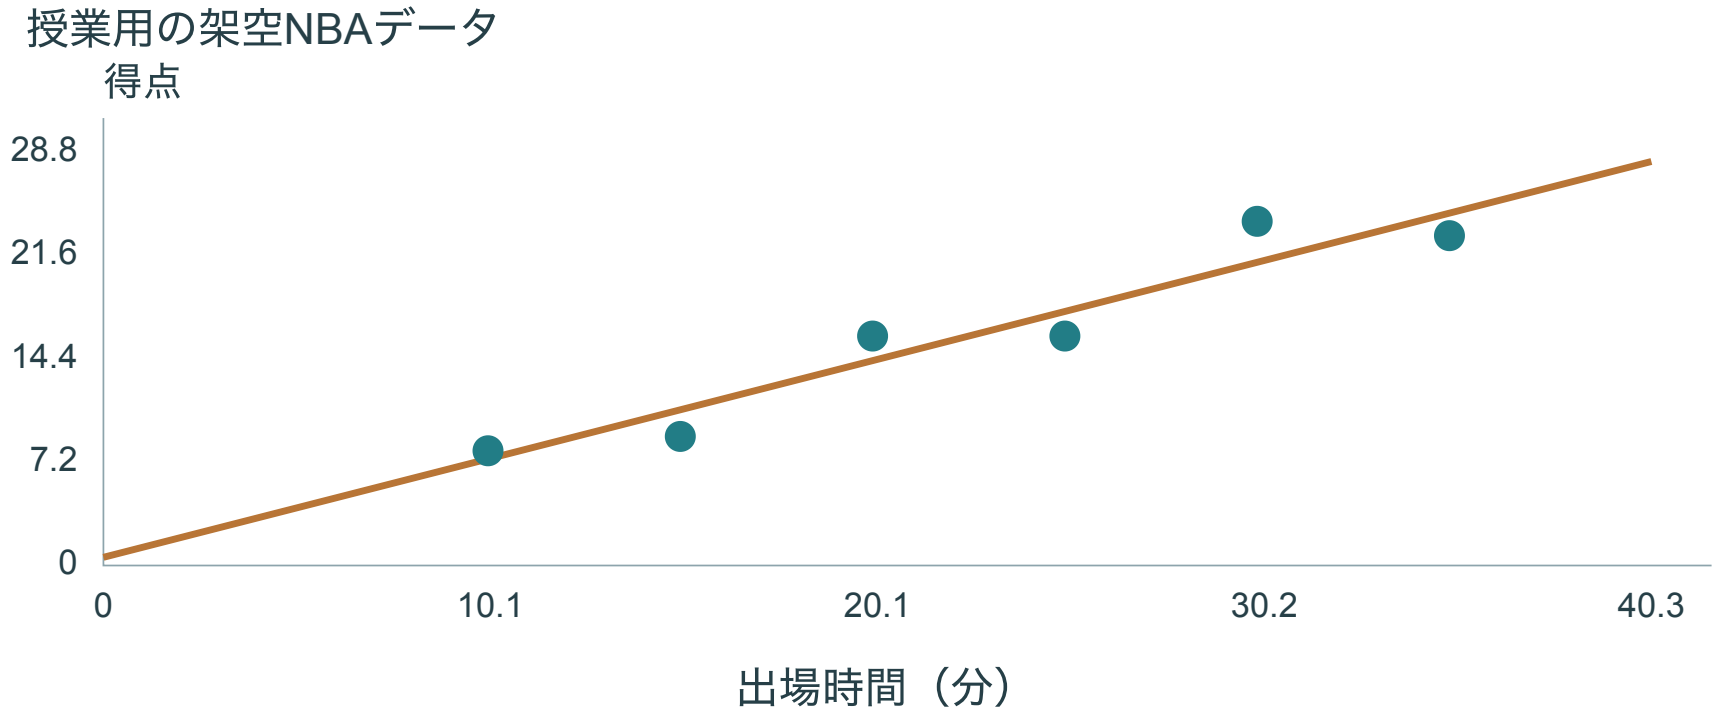
a：切片。x＝0での直線の高さ。

b：回帰係数（かいきけいすう）。xが1増えたときの、直線の上がり方。

u：直線では説明しきれないずれ。

教科書 p.71

点の間に、直線を引く

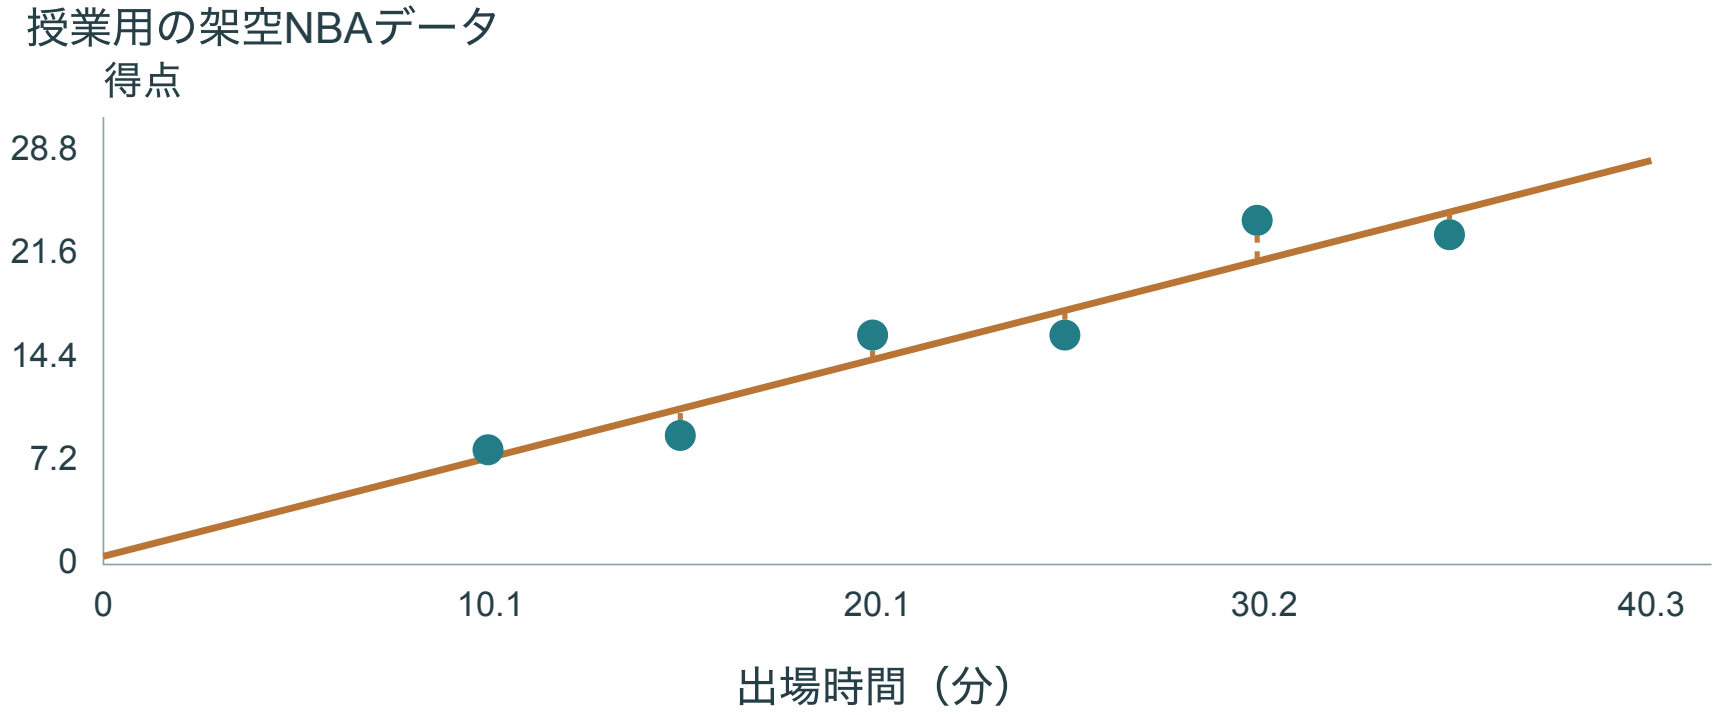


すべての点を通るとは限らない。

最小二乗法（さいしょうにじょうほう）

Least squares

点から直線まで、縦に測る



観測したy − 直線が予測するy ＝ 残差（ざんさ）。

教科書 p.71〜

残差（ざんさ）を二乗して、合計を小さくする

正負を打ち消さず、
ずれの大きさを比べる。

教科書 p.71〜

やってみよう！

Move the line, inspect the residuals

直線を動かし、残差（ざんさ）の二乗和を見る

やってみよう！ ↗

まず予想する → 数値を変える → グラフと計算を確かめる。

この架空データから得た直線

$$\hat{y} = 0.5714 + 0.6857x$$

出場時間が1分増えると、予測得点は約0.686点増える。

教科書 p.71

25分なら、約17.71点と予測

① 与えられた条件 / Given

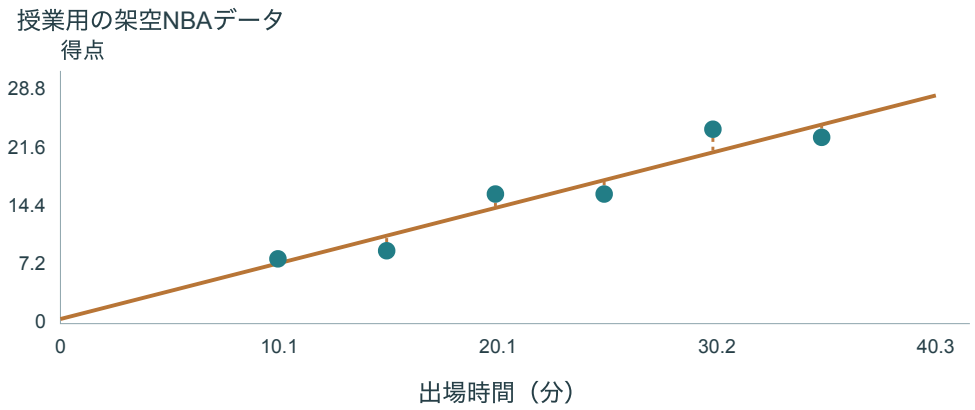
授業用の6試合。推定した切片0.5714、係数0.6857。

② 公式 / Formula

$$y_i = a + bx_i + u_i$$

③ 代入・計算 / Substitute

$$\hat{y} = 0.5714 + 0.6857 \times 25 \approx 17.71$$



④ 実測16点との残差(ざんさ)は、16−17.71＝約−1.71点。

教科書 p.71（回帰分析(かいきぶんせき)）

0分でも、0.57点？

直線の切片を、そのまま現実の得点だとは考えない。

観測した範囲は10〜35分。

データの外への予測には注意する。

教科書 p.71〜

チャレンジ1　別の練習用の回帰式を読む

自分で解く　8分 ／ 独立した授業内練習

架空の回帰式：予測得点＝2＋0.6×出場時間。

(1) 30分の予測得点。
(2) 出場時間が5分増えたときの予測得点の変化。

参考の公式（数値は自分で代入）

$$y_i = a + bx_i + u_i$$

教科書 p.71（回帰分析）

式に入れ、係数を単位で説明する

① 与えられた条件 / Given

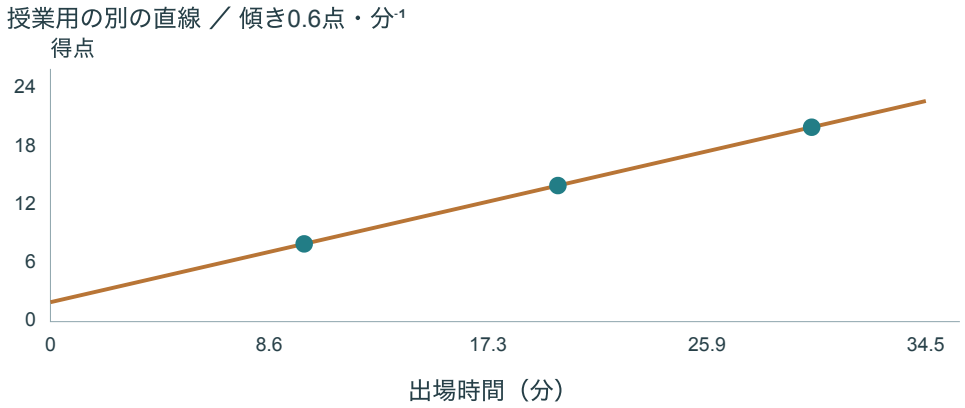
a＝2点、b＝0.6点／分。

② 公式 / Formula

$$y_i = a + bx_i + u_i$$

③ 代入・計算 / Substitute

$$\hat{y}(30) = 2 + 0.6 \times 30 = 20, \qquad \Delta\hat{y} = 0.6 \times 5 = 3$$



④ 予測20点。5分増なら、予測得点は3点増。因果効果とは断定しない。

教科書 p.71（回帰分析）

Excelで分析する

Run a regression in Excel

データ分析ツールを使えるようにする

Windows：ファイル → オプション → アドイン。

Mac：ツール → Excelアドイン。

分析ツールを有効にし、データ分析 → 回帰(かいき)分析(ぶんせき)。

Y範囲とX範囲を、取り違えない

例：A列は試合、B列は出場時間、C列は得点。

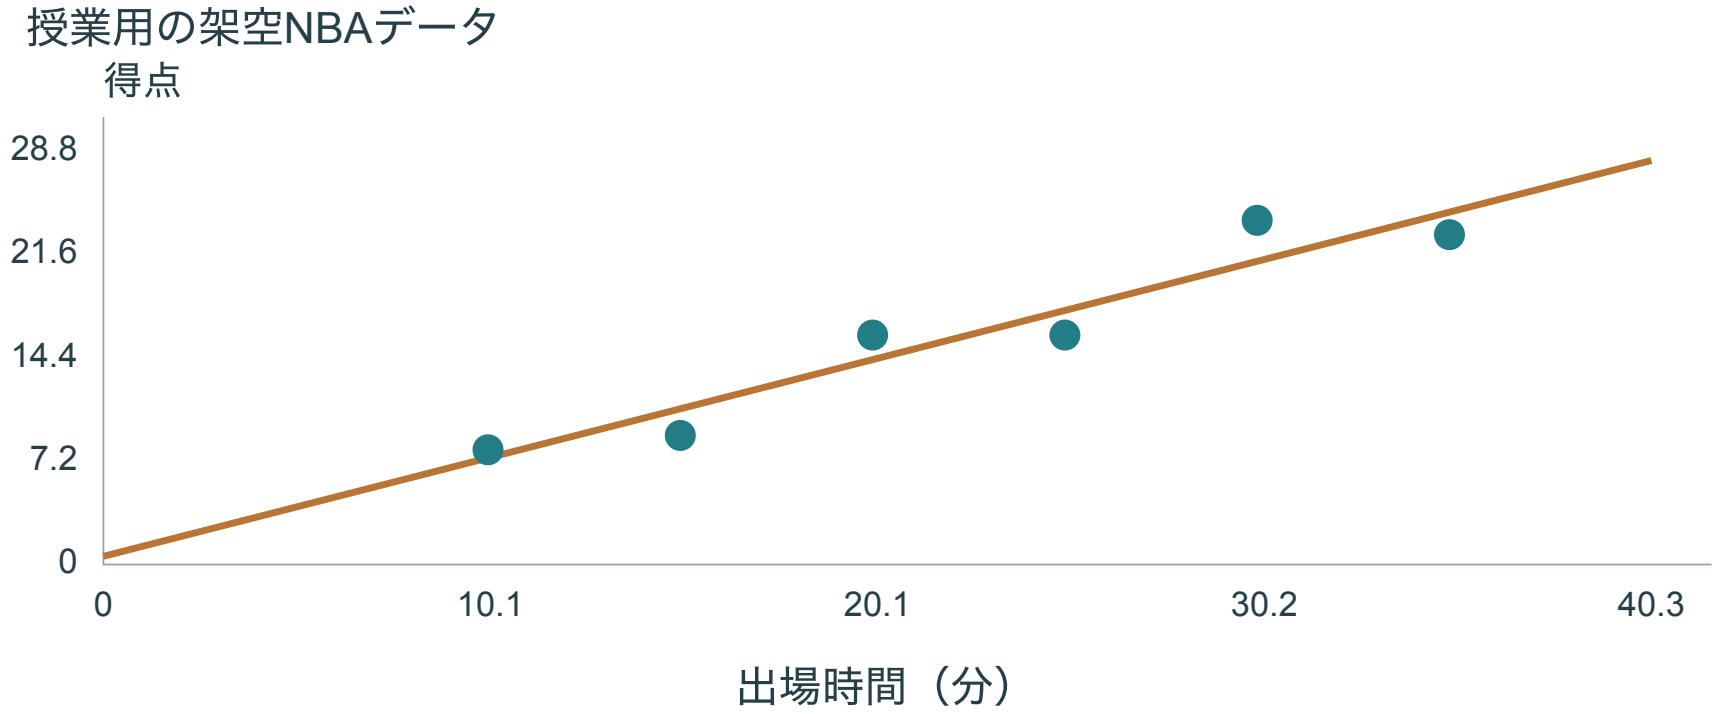
入力Y範囲：C列の得点。入力X範囲：B列の出場時間。

見出しを選ぶなら、「ラベル」も指定する。

まず、6個の観測を使ったと確認する

出力の項目	この架空データの値
観測数	6
決定係数 R^2	0.9102
自由度修正済み R^2	0.8878
出場時間の回帰係数	0.6857

R^2は、直線の当てはまりの目安



この標本では、得点のばらつきの約91％を直線で説明。
予測が91％の確率で当たる、とは言わない。

教科書 p.71〜

係数・標準誤差・t値・p値を見る

出場時間の項目	値
係数	0.6857
係数の標準誤差	0.1077
t値	6.3689
p値	0.00312

帰無仮説は、傾きが0

H_0：母集団の回帰係数$b=0$。H_1：$b\neq0$。

この出力のt値：$0.6857 \div 0.1077 \approx 6.37$。

$p \approx 0.00312 < 0.05$。傾き0のH_0を棄却する。

教科書 p.71〜・138〜

有意でも、原因だとは証明しない

関連の証拠と、
因果関係（いんがかんけい）の証拠は、別。

やってみよう！

Read the regression output

点を変えると、Excel形式の出力も動く

やってみよう！ ↗

まず予想する → 数値を変える → グラフと計算を確かめる。

チャレンジ2　有意でない係数を、どう説明する？

自分で解く　6分 ／ 独立した授業内練習

別の架空データ：出場時間10、15、20、25、30分。
得点15、8、18、9、17点。

出力：係数0.10、p＝0.7830、R^2＝0.0293。
「時間と得点は無関係と証明した」は正しいか？

参考の公式（数値は自分で代入）

$$y_i = a + bx_i + u_i$$

教科書 p.71（回帰分析）

「証拠が十分でない」と説明する

① 与えられた条件 / Given

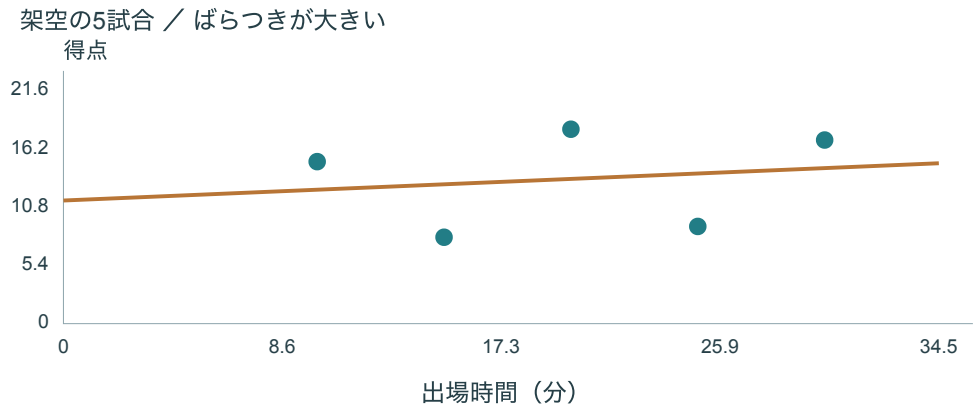
5試合。推定係数0.10、p≈0.7830、R²≈0.0293。

② 公式 / Formula

$$y_i = a + bx_i + u_i$$

③ 代入・計算 / Substitute

$$\hat{y} = 11.4 + 0.10x, \qquad p \approx 0.7830 > 0.05$$



④ 傾き0を棄却できない。関連がないと証明したわけではない。

教科書 p.71（回帰分析）

自分たちの二つの数値なら？

任意・匿名：練習した分数と、タイピングの打鍵数。

ペアの対応を崩さずに入力する。

人数が少ないことや、経験の違いも解釈に添える。

やってみよう！

Class scatterplot

匿名のペアデータを、点と直線にする

やってみよう！ ↗

まず予想する → 数値を変える → グラフと計算を確かめる。

結果は、4つを一緒に説明する

① 何をxとyにしたか。
② 係数の大きさと単位。
③ R^2とp値。
④ 因果と予測範囲の限界。

ALのExcelファイルは、自分で分析する

対象となる列を確認して、散布図から始める。

授業の架空NBAデータと、ALのデータは別。

課題の回帰係数・セルの答えは公開しません。

時間があれば：外れ値を1点足す

同じデータに1点だけ追加したら、傾きはどれだけ動く？

まず予想し、探索で確かめる。

直線を引いた後が、大事。

数字を出すことと、
正しく読むこと。