

$$\begin{aligned}\Pr(X=3) &= {}_n C_x \pi^x (1-\pi)^{n-x} = {}_5 C_3 (0.32)^3 (1-0.32)^{5-3} \\ &= 10 \times 0.032768 \times 0.4624 = 0.151519\end{aligned}$$

よって5回中3回ヒットを打つ確率は0.15=15%程度ということになる。

以上のことから、二項分布に従う確率分布においては、試行回数 n と、事象が起こる確率 π がわかれば、確率を計算できることがわかる。よって、確率変数 X の分布が二項分布である場合、「確率変数 X は二項分布 $B(n, \pi)$ に従う」といい、 $X \sim B(n, \pi)$ と表記する。ここでの B は二項分布 (Binomial distribution) の頭文字、 $\sim$ は「従う」の意味である。

② 確率変数が二項分布に従うときの期待値と分散

二項分布に従う確率変数 X の期待値 $E(X)$ と分散 $Var(X)$ は以下の式で定義できる。期待値とは前述の通り、確率変数がとる値を、その確率によって重み付けした平均値 (加重平均¹⁾) のことである。

$$\begin{aligned}E(X) &= n\pi \\ Var(X) &= n\pi(1-\pi)\end{aligned}$$

③ ポアソン分布

ポアソン分布 (Poisson distribution) は、二項分布の特殊型の1つである。二項分布における、事象が「起こる確率 π 」が極端に小さく、かつ試行回数 n が十分に大きい場合に用いられる。例えば、1日当たりの死亡事故件数や生産ラインに不良品が混ざる件数、1分間当たりの来店者数などがポアソン分布に従うと考えられる。

起こる確率 π が極端に小さいとは、具体的には $(1-\pi) \div 1$ とみなせる場合である。例えば $\pi = 0.0000001$ である場合、 $(1-\pi) = 0.9999999$ となり、ほぼ1とみなすことができる。よって、ポアソン分布に従う確率変数 X の期待値 $E(X)$ と分散 $Var(X)$ は以下の式で定義できる。

$$\begin{aligned}E(X) &= n\pi \\ Var(X) &= n\pi\end{aligned}$$

1) 加重平均については1章4節参照。

5 連続確率分布

連続確率分布の場合はより複雑である。確率を計算するためには、累積度数に対応する分布関数¹⁾ $F(x) = \Pr(X \leq x)$ を想定し、この分布関数を積分した確率密度関数 $f(x)$ ²⁾ を計算する必要がある。ただし統計学において必要なのは、積分の計算を行うことではなく、**面積を表すものであるという概念**である。図1は分布関数 $F(x) = \Pr(X \leq x)$ のグラフである。横軸は確率変数のとりうる値 x 、縦軸は $F(x)$ である。このグラフのうち、直線部分の横軸の値を y 、縦軸の値を $F(y)$ とする。一方、図2は確率密度関数 $f(x)$ のグラフである。横軸は同じく x 、縦軸は $f(x)$ である。横軸上に分布関数と同じ y の値をとると、確率密度関数 $f(x)$ のグラフと、横軸 x 、横軸上の値 y で囲まれた斜線部分を考えることができる。この斜線部分の面積が、左図の分布関数の縦軸の値 $F(y)$ であり、確率変数 y に対応する確率である。




図1. 分布関数 $F(x)$




図2. 確率密度関数 $f(x)$

確率の合計は1となることより、横軸すなわち確率変数 x のとりうる範囲の左端 $-\infty$ から右端 $+\infty$ までのすべての範囲を考えた場合の確率密度 $\int_{-\infty}^{+\infty} f(x) dx = 1$ となる (図3)。さらに、確率は必ず0から1の間の値をとるため、必ず確率密度の値は正となる³⁾。

また、確率変数 x が a から b の間である確率 $\Pr(a \leq x \leq b)$ も、面積の計算から求めることができる (図4)。横軸左端の $-\infty$ からの面積を考えれば、ま

1) 分布関数は単調に増加する関数であり、 $F(-\infty) = 0$ かつ $F(+\infty) = 1$ である。

2) $F(x) = \int_{-\infty}^x f(x) dx$ とする。

3) $f(x) \geq 0$

ず $-\infty$ から β までの面積を求め、 $-\infty$ から a までの面積（図中の白い部分）を引けば、 a から β までの面積（図中の縦線部分）を求めることができる¹⁾。




図 3. 確率密度関数の例①




図 4. 確率密度関数の例②

① 正規分布

正規分布 (normal distribution) は、連続確率分布の 1 つである。1 章 3 節で述べた通り、①中心が平均値であること、②左右対称であること、③単峰型であること、④横軸が漸近線となること、⑤分散（標準偏差）によって形状が変わること、が正規分布の特徴である。

母集団の分布がどのような分布であっても、無作為抽出した標本における和の分布は、標本の大きさ n が十分に大きいときには正規分布になることが知られている。これを**中心極限定理**という。これを母集団から無作為抽出した標本平均²⁾に適用すると、**中心極限定理により標本平均は正規分布に従う**といえる。つまり、正規分布の確率密度が計算できれば、母集団がどのような分布であったとしても、標本平均に関しては確率の計算ができるといえる。一方で、正規分布の確率の計算は以下の式で定義され、非常に複雑である。

$$\Pr(a < X < \beta) = \int_a^\beta f(x) dx = \int_a^\beta \frac{1}{\sqrt{2\pi\sigma_x^2}} \exp\left\{-\frac{(x-\mu_x)^2}{2\sigma_x^2}\right\} dx$$

まず、式中に母平均 μ_x と母分散 σ_x^2 が含まれていることから、母平均・母分散の双方が既知であることが必要である。そして、積分記号 $\int$ が含まれて

1) 数式で表現すると、

$$\Pr(a < x < \beta) = \int_a^\beta f(x) dx = \int_{-\infty}^\beta f(x) dx - \int_{-\infty}^a f(x) dx$$

となる。

2) 標本平均は、係数 $\frac{1}{n}$ を確率変数の和にかけた形、すなわち $\bar{x} = \frac{1}{n}(x_1 + x_2 + \cdots + x_n)$ であるため、「和の分布」であるといえる。

いることから、母平均や母分散が変わるたびに、すなわち母集団のデータが変わるたびに、複雑な積分の計算が必要であることがわかる。

そこで、1 章 5 節で述べた標準化¹⁾を、正規分布に適用する。標準化とは、平均値と標準偏差（分散）を統一する方法で、平均値=0、標準偏差=1 となる。正規分布に標準化を適用することで、母平均=0、母分散=1 となり、複雑な計算は一度だけ実施すればよいことになる。このように、標準化を適用した正規分布のことを**標準正規分布** (standard normal distribution) という。確率変数である標本平均 $\bar{X}$ を標準化した確率変数は以下の式で定義できる。

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu_x}{\sqrt{\frac{\sigma_x^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{母分散}}{\text{標本数}}}}$$

確率変数 Z は平均 0、分散 1 の正規分布に従う²⁾といえる。また、確率変数 Z の値 z ($Z=z$) に対応した標準正規分布の上側確率 $\Pr(Z > z)$ は、標準正規分布表（巻末）³⁾で求めることができる。確率変数 Z の値 z とは、図 5 中における横軸上のある点 z 、上側確率 $\Pr(Z > z)$ とは、標準正規分布のグラフと横軸上の点 z 、横軸で囲まれた斜線部の面積で、確率変数 $Z=z$ のときの確率を表す。




図 5. 標準正規分布における上側確率

1) 標準化の適用できないケースとして、①はずれ値が存在する場合、②度数分布が左右対称でない場合、③度数分布が単峰型でない場合、が考えられるが、いずれも正規分布の特徴には当てはまらないため、正規分布には標準化を適用することができる。

2) 標準正規分布は平均 0、分散 1 の正規分布であるため、 $Z \sim N(0, 1)$ とも書ける。

3) 標準正規分布表を含む確率分布表は、ほとんどの統計学の教科書や参考書に収録されている。いずれの教科書においても同じ値であることを確認したい。

② 標準正規分布表の読み方

標準正規分布表は確率変数 Z の値 z に対応した確率を一覧表にしたものであるため、表側と表頭から z の値を探せばよい。以下に例を示す。

例① $z=1.96$ に対応する上側確率を求めたい

手順1) 表側から 1.9 を探す

手順2) 表頭から 0.06 を探す

手順3) 表側と表頭が交差したところの値 0.02500 が求めたい確率である
すなわち $\Pr(Z > 1.96) = 0.02500$ である。




図 6. 標準正規分布における例①
上側確率を求める場合




図 7. 標準正規分布における例②
下側確率を求める場合

例② $z=-1.96$ に対応する下側確率を求めたい

z がマイナスの場合は、対応する確率は標準正規分布表には記載されていないが、その場合は正規分布が左右対称である特徴を利用すればよい。すなわち、 $z=1.96$ のときの上側確率（図 6 における斜線部の面積）と、 $z=-1.96$ のときの下側確率（図 7 における斜線部の面積）は等しい。

例③ $z=1.96$ に対応する下側確率を求めたい

この場合も、正規分布が左右対称であること、確率の合計は 1 であることを利用すればよい。すなわち、 $z=1.96$ のときの上側確率（図 6 における斜線部の面積）を 1 から引けば、 $z=1.96$ のときの下側確率（図 8 における斜線部の面積）を求めることができる。

例④ $-1 < z < 1$ に対応する確率を求めたい

手順1) まず $z=1.00$ のときの上側確率を表から探す

$\Pr(Z=1.00) = 0.1586$ （図 9 中右側の空白の面積）

手順2) 正規分布は左右対称であるため、 $z=-1.00$ のときの下側確率も同じ 0.1586 となる（図 9 中左側の空白の面積）




図 8. 標準正規分布における例③
下側確率を求める場合




図 9. 標準正規分布における例④

手順3) 確率の合計は 1 であるため、 0.1586×2 を 1 から引く（図 9 中斜線部の面積）

すなわち $\Pr(-1 < Z < 1) = 1 - (0.1586) \times 2 = 0.6828$ である。

③ t 分布

t 分布 (t-distribution) は、連続確率分布の 1 つである。以下の標準正規分布に従う確率分布 Z では、母平均と母分散がともに既知である場合に、対応する確率を計算することができた。

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu_x}{\sqrt{\frac{\sigma_x^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{母分散}}{\text{標本数}}}}$$

ここで、分母にある母分散 σ_x^2 が未知の場合に、母分散 σ_x^2 の代わりに後で説明する標本不偏分散 $\hat{\sigma}_x^2$ を用いて標準化した場合、標準化した標本平均は t 分布と呼ばれる確率分布に従う。標本不偏分散については後述する。

$$T = \frac{\bar{X} - \mu_x}{\sqrt{\frac{\hat{\sigma}_x^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{標本不偏分散}}{\text{標本数}}}}$$

確率変数 T は自由度 $(n-1)$ の t 分布に従うといい、 $T \sim t(n-1)$ と表記する。ここで、 t は t 分布の頭文字であり、 $(n-1)$ は自由度である。

自由度とは自由に動くことのできる変数の数のことを指す。例として、 $\{2, x, 5, 1\}$ の 4 つのデータがあるとする。これだけでは、未知のデータ x がいくつなのかはわからない。ここで、平均値 $= 3$ という条件を課すと、 $\frac{1}{4}(2+x+5+1) = 3$ より、 $x=4$ であることがわかる。このように、 n 個のデー

タにおいて、等式（条件式）が k 個与えられたとき、 $(n-k)$ 個の値が明らかになれば、 n 個すべての値が明らかになる。この $(n-k)$ のことを自由度といい、 v で表されることが多い。例においては、与えられた等式は平均値 $\frac{1}{n} \sum x_i = 3$ の 1 つであるため、 $k=1$ であり、自由度 v は $(n-1)$ である。

標本不偏分散は以下の式で定義される。

$$\begin{aligned}\widehat{\sigma_x^2} &= \frac{1}{n-1} \sum (X_i - \bar{X})^2 = \frac{1}{\text{自由度}} \sum |(\text{元のデータ}) - (\text{標本平均})|^2 \\ &= \frac{1}{\text{自由度}} \sum (\text{標本平均からの偏差二乗})\end{aligned}$$

標本分散は、標本平均からの偏差二乗和 $(x_i - \bar{X})^2$ を、標本数 n で割ったものであったが、標本不偏分散は自由度 $n-1$ で割ったものである¹⁾。

t 分布は左右対称の確率分布であるが、その形状は自由度 v によって変化する。自由度 v の値が大きくなるにつれて、 t 分布の形状は標準正規分布に近似する。




図 10. 標準正規分布と自由度 1, 4, 10 の t 分布

④ t 分布表の読み方

t 分布表は確率変数 T のパーセント点 $t_a(v)$ を一覧表にしたものである。表側に t 分布の形状を決める自由度 v 、表頭に上側確率 α が表記されている。図 11 中の横軸上の値が確率変数 T のパーセント点 $t_a(v)$ 、斜線部の面積が上側確率 α 、グラフの形状が自由度 v によって変化する²⁾。

1) 導出については Web 上に掲載の補論 3 を参照のこと。

2) ただし確率分布であるため、形状（自由度）が変化しても全体の面積（確率の合計）は 1 である。




図 11. t 分布




図 12. t 分布における例②

例① 自由度 $v=20$ 、上側確率 $\alpha=0.025$ のときのパーセント点、 $t_{0.025}(20)$ を求めたい

手順 1) 表側から、自由度 20 を探す

手順 2) 表頭から、上側確率 0.025 を探す

手順 3) 表側と表頭が交差したところの値 2.0860 が求めたい t の値（パーセント点）である

例② 自由度 $v=10$ のとき、 $\Pr(-t_a(v) < T < t_a(v)) = 0.90$ となるパーセント点、 $t_a(v)$ を求めたい

手順 1) 図 12 における斜線部の面積が 0.90 となるときのパーセント点を求める場合である。確率の合計は 1 であることから、両端の確率（図 12 中の空白の面積）の合計は $1 - 0.90 = 0.10$ である。

手順 2) t 分布は左右対称であるため、図 12 中の空白の面積は等しくなる。よって、上側確率（図 12 中の右側の空白の面積）は $\frac{1}{2} \times 0.10 = 0.05$ となり、 $\alpha = 0.05$ である。

手順 3) 文意より自由度 $v=10$ 、手順 2 より上側確率 $\alpha = 0.05$ となるため、対応するパーセント点を t 統計表より読み取る。 t 統計表より、

$$t_a(v) = t_{0.05}(10) = 1.8125$$

⑤ カイ二乗分布

カイ二乗分布 (chi-squared distribution)¹⁾ は、連続確率分布の 1 つであり、標準正規分布にしたがう統計量の平方和に関する確率分布である。確率変数 U

1) カイ二乗分布の「カイ」はギリシャ文字のカイ χ に由来する。「 χ^2 分布」と表記することもある。アルファベットの X と混同しないように注意したい。

が、自由度 v のカイ二乗分布にしたがうとき、 $U \sim \chi^2(v)$ と表記する。カイ二乗分布の平均値は自由度 v 、分散は $2v$ となる。カイ二乗分布は左右非対称の確率分布であるが、自由度 v が大きくなるにつれて、左右対称の形状へと変化していき、自由度 v が十分に大きいときには正規分布に近似するという特徴がある。図 13 はそれぞれ、自由度 10, 20, 30, 40, 50 のカイ二乗分布を図示したものである。自由度の値が大きくなるにつれて、左右対称の形状へと変化していることがわかる。




図 13. カイ二乗分布

カイ二乗分布にしたがう統計量 U は、以下の式で定義される¹⁾。

$$U_0 = \frac{\sum_{i=1}^n (x_i - \mu_x)^2}{\sigma_x^2} = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sigma_x^2} + \frac{n(\bar{X} - \mu_x)^2}{\sigma_x^2}$$

上記の式を、日本語で書き下すと次のようになる。

母平均からの偏差二乗和
母分散

$$= \frac{\text{標本平均からの偏差二乗和}}{\text{母分散}} + \frac{(\text{標本数}) \times (\text{標本平均} - \text{母平均})^2}{\text{母分散}}$$

左辺 $\frac{\sum_{i=1}^n (x_i - \mu_x)^2}{\sigma_x^2}$ は自由度 n のカイ二乗分布にしたがう、右辺第 1 項

$\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sigma_x^2}$ は自由度 $(n-1)$ のカイ二乗分布に、右辺第 2 項 $\frac{n(\bar{X} - \mu_x)^2}{\sigma_x^2}$ は

自由度 1 のカイ二乗分布にそれぞれしたがう。

1) 導出については Web 上の補論 1 を参照のこと。

6 確率分布の平均値と分散

確率分布は母集団の分布であるといえる。すなわち、確率分布の平均値と分散を求めることができれば、母集団の平均値（母平均 μ_x ）と、母集団の分散（母分散 σ_x^2 ）の値を求めることができる。確率分布の平均値と分散は、以下の式で定義される。

◎離散確率分布の平均値 $\mu_x = \sum_x x \Pr(X=x)$

◎連続確率分布の平均値 $\mu_x = \int_{-\infty}^{+\infty} x f(x) dx$

まず確率分布の平均値、すなわち母平均 μ_x から考える。離散確率分布の場合の $\sum$ と、連続確率分布の場合の $\int$ はいずれも「合計」を表すものと考えればよい。何を合計するかをみると、離散確率分布の場合は $x \Pr(X=x)$ である。これは、確率変数 X がとりうる値 x と、確率変数 X が x である確率 $\Pr(X=x)$ の積である。すなわち、(確率変数 X がとりうる値 x) $\times$ ($X=x$ になるときの確率) をそれぞれ計算し、すべての x について合計したものが、確率分布の平均値 (= 母平均 μ_x) となる。連続確率分布の場合はより複雑そうに見えるが、同じく (確率変数 X がとりうる値 x) $\times$ ($X=x$ になるときの確率) をそれぞれ計算し、すべての範囲 $-\infty$ から $+\infty$ までを合計したものが確率分布の平均値 (= 母平均 μ_x) となる。連続確率分布の場合は、確率変数 X が x である確率が $\Pr(X=x)$ ではなく $f(x) dx$ である。

◎離散確率分布の分散 $\sigma_x^2 = \sum_x (x - \mu_x)^2 \Pr(X=x)$

◎連続確率分布の分散 $\sigma_x^2 = \int_{-\infty}^{+\infty} (x - \mu_x)^2 f(x) dx$

確率分布の分散、すなわち母分散については、上述の平均値の式から一部を変更することで計算することができる。平均値の場合は確率変数 X がとりうる値 x を代入していたところを、確率変数 X がとりうる値 x と母平均 μ_x の差の二乗、すなわち母平均からの偏差の二乗を代入すればよい。