

STATION


統計学B

Week 7


Let's kiss 🍷












Will they ever kiss?



The Dichotomy Paradox

ゼノンの二分法のパラドクスとは



連續確率分布

continuous probability distribution

$$Pr(X = x) = 0$$

連続確率変数に対応する確率 $Pr(X = x)$ は **ゼロ** になる

😞 え？ なんで？

A hand-drawn illustration of a landscape. At the top left, a diagonal line with cross-ticks represents a railway track, with a rectangular box labeled 'STATION' in blue capital letters. A light blue wavy line representing a river flows from the bottom left towards the right. Scattered throughout the scene are several green circular trees with black outlines and several simple black-outlined buildings of various shapes. A small stick figure carrying a bag is walking along the riverbank on the right side.

STATION

- There are no "exact" values
 - $Pr(X = x) = 0$
- 連続変数では相対度数は表現できないが、
- 連続変数では累積度数は表現できる
 - 駅からの距離480m0cm0mmちょうど
どの物件はほぼないが、
 - 駅からの距離480m以下の物件数
は計算できる


But really?
How tall are you?
Or...

Imagine the number π

Is it 3.14?
Or 3.14159?
...or... 3.141592653589793... ?

$F(x)$ 分布関数


Cumulative Distribution Function: CDF



(a) 分布関数 $F(x)$

- 単調に増加する関数
 - 減少することがない
- x の取り得る値は $-\infty$ から ∞ の間
 - $F(-\infty)=0$
 - $F(+\infty)=1$

💡 Lightbulb lifespan 💡




(a) 分布関数 $F(x)$

寿命（時間）：

- $F(1000) = 0.10$
- $F(5000) = 0.90$

🍜 ラーメン屋 🍜



(a) 分布関数 $F(x)$

待ち時間（分）：


- $F(20) = 0.10$
- $F(60) = 0.90$

確率密度関数

The probability density function (PDF)


$$F(y) = \int_{-\infty}^y f(x) dx$$

$$\int_{-\infty}^{\infty} f(x) \, dx = 1$$




- test scores 100
- human heights 🧑


$$\int_{-\infty}^y f(x) \, dx$$




$$\int_{\alpha}^{\beta} f(x) \, dx$$




確率密度分布 $f(x)$ と x 軸の間の面積は1




x が y のときの $f(x)$ と x 軸で囲まれた部分の面積




分布関数 $F(x)$




色部分の面積 $\Pr(\alpha < X < \beta)$ の求め方




緑の面積から赤の面積を引く



緑の面積から赤の面積を引く



$$\Pr(\alpha < X < \beta) = F(\beta) - F(\alpha)$$



p52

$$\Pr(\alpha < X < \beta) = \int_{\alpha}^{\beta} f(x) dx = F(\beta) - F(\alpha)$$

定義7 ☆☆☆




図 4-3 連続確率変数における分布関数と確率密度関数の関係、
確率密度関数による確率の定義

正規分布とカイ二乗分布

Normal Distribution and Chi-Square Distribution

正規分布の確率計算p122

- 正規分布 （復習）
 - 平均を中心とした左右対称の連続確率分布
- 中心極限定理 （復習）
 - 標本平均は正規分布にしたがう
 - 母集団がどのような分布であっても
標本平均に関しては確率による評価ができる
 - 確率計算は簡単ではない...

$$Pr(\alpha < X < \beta) = \int_{\alpha}^{\beta} f(x)dx = \int_{\alpha}^{\beta} \frac{1}{\sqrt{2\pi}\sigma_X^2} \exp\left\{-\frac{(x - \mu_X)^2}{2\sigma_X^2}\right\} dx$$

μ and σ

(2) 標準正規分布

standard normal distribution

Z

標準正規分布

- 標準化（復習）
 - 平均値と標準偏差を統一する方法
 - 平均 = 0
 - 標準偏差 = 1
- 標準化が適用できない場合
 - データに外れ値が含まれる場合
 - 度数分布が左右対称の単峰の分布でない場合
 - 正規分布は左右対称の確率分布で外れ値が生じない形状なので標準化を適用できる！

標準正規分布

Standardization of the normal distribution

- 標本平均 $\bar{X}$ を標準化する
- Z : $\bar{X}$ を標準化した確率変数

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu_X}{\sqrt{\frac{\sigma_X^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{母分散}}{\text{標本数}}}}$$

Say what?

Ok, imagine 期末試験クラス平均 $\mu = 50$
Standard deviation $\sigma = 10$

Your test score = 60
What is your Z score?

$$Z = \frac{X - \mu}{\sigma}$$

Using the numbers:

$X = 60$ (individual's score)

$\mu = 50$ (population mean)

$\sigma = 10$ (population standard deviation)


$$Z = \frac{60 - 50}{10} = \frac{10}{10} = 1$$

標準正規分布表

標準正規分布の上側確率

標準正規分布表では $z=0.00\sim 3.09$ における標準正規分布 $N(0, 1)$ の上側確率 $\Pr(Z > z)$ を表す。

たとえば, $z=2.58$ のとき, 表側の 2.5 と表頭の 0.08 との交差点である 0.00494 が上側確率 $\Pr(Z > 2.58) = 0.00494$ となる。また, 標準正規分布は左右対称のため, $\Pr(-2.58 < Z < 2.58) = 1 - 2 \times 0.00494 \approx 0.99$ となる。



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48405	0.48006	0.47608	0.47210	0.46812	0.46414
0.1	0.46017	0.45620	0.45224	0.44828	0.44433	0.44038	0.43644	0.43251	0.42858	0.42465
0.2	0.42074	0.41683	0.41294	0.40905	0.40517	0.40129	0.39743	0.39358	0.38974	0.38591
0.3	0.38209	0.37828	0.37448	0.37070	0.36693	0.36317	0.35942	0.35569	0.35197	0.34827
0.4	0.34458	0.34090	0.33724	0.33360	0.32997	0.32636	0.32276	0.31918	0.31561	0.31207
0.5	0.30854	0.30503	0.30153	0.29806	0.29460	0.29116	0.28774	0.28434	0.28096	0.27760
0.6	0.27425	0.27093	0.26763	0.26435	0.26109	0.25785	0.25463	0.25143	0.24825	0.24510
0.7	0.24196	0.23885	0.23576	0.23270	0.22965	0.22663	0.22363	0.22065	0.21770	0.21476
0.8	0.21186	0.20897	0.20611	0.20327	0.20045	0.19766	0.19489	0.19215	0.18943	0.18673
0.9	0.18406	0.18141	0.17879	0.17619	0.17361	0.17106	0.16853	0.16602	0.16354	0.16109
1.0	0.15866	0.15625	0.15386	0.15151	0.14917	0.14686	0.14457	0.14231	0.14007	0.13786

Now imagine...

「標本」 の場合は？

You take a sample

$$n = 4$$

and the sample mean

$$\bar{X} = 60$$
 ✨👏

What is this sample mean's Z score?

$$Z = \frac{\bar{X} - \mu_x}{\frac{\sigma_x}{\sqrt{n}}}$$


🤔 ちょっと違うぞ！

- $\bar{X} = 60$ (sample mean)
- $\mu_X = 50$ (population mean)
- $\sigma_X = 10$ (population standard deviation)
- $n = 4$ (sample size)

$$Z = \frac{60 - 50}{\frac{10}{\sqrt{4}}}$$

標準正規分布表の見方


超重要！



標準正規分布表

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48405	0.48006	0.47608	0.47210	0.46812	0.46414
0.1	0.46017	0.45620	0.45224	0.44828	0.44433	0.44038	0.43644	0.43251	0.42858	0.42465
0.2	0.42074	0.41683	0.41294	0.40905	0.40517	0.40129	0.39743	0.39358	0.38974	0.38591
0.3	0.38209	0.37828	0.37448	0.37070	0.36693	0.36317	0.35942	0.35569	0.35197	0.34827
0.4	0.34458	0.34090	0.33724	0.33360	0.32997	0.32636	0.32276	0.31918	0.31561	0.31207
0.5	0.30854	0.30503	0.30153	0.29806	0.29460	0.29116	0.28774	0.28434	0.28096	0.27760
0.6	0.27425	0.27093	0.26763	0.26435	0.26109	0.25785	0.25463	0.25143	0.24825	0.24510
0.7	0.24196	0.23885	0.23576	0.23270	0.22965	0.22663	0.22363	0.22065	0.21770	0.21476
0.8	0.21186	0.20897	0.20611	0.20327	0.20045	0.19766	0.19489	0.19215	0.18943	0.18673
0.9	0.18406	0.18141	0.17879	0.17619	0.17361	0.17106	0.16853	0.16602	0.16354	0.16109

標準正規分布表の見方



例) $z=2.00$ のとき

まず縦方向から
2.0を探す

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48405	0.48006	0.47608	0.47210	0.46812	0.46414
0.1	0.46017	0.45620	0.45224	0.44828	0.44433	0.44038	0.43644	0.43251	0.42858	0.42465
0.2	0.42074	0.41683	0.41294	0.40905	0.40517	0.40129	0.39743	0.39358	0.38974	0.38591
0.3	0.38209	0.37828	0.37448	0.37070	0.36693	0.36317	0.35942	0.35569	0.35197	0.34826
.....										
1.8	0.03593	0.03515	0.03438	0.03362	0.03288	0.03216	0.03144	0.03074	0.03005	0.02937
1.9	0.02872	0.02807	0.02743	0.02680	0.02619	0.02559	0.02500	0.02442	0.02385	0.02329
2.0	0.02275	0.02222	0.02169	0.02118	0.02068	0.02018	0.01970	0.01923	0.01876	0.01831
2.1	0.01786	0.01743	0.01700	0.01659	0.01618	0.01578	0.01539	0.01500	0.01463	0.01426

例) $z=2.00$ のとき

次に横方向から
0.00を探す

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48405	0.48006	0.47608	0.47210	0.46812	0.46414
0.1	0.46017	0.45620	0.45224	0.44828	0.44433	0.44038	0.43644	0.43251	0.42858	0.42465
0.2	0.42074	0.41683	0.41294	0.40905	0.40517	0.40129	0.39743	0.39358	0.38974	0.38590
0.3	0.38209	0.37828	0.37448	0.37070	0.36693	0.36317	0.35942	0.35569	0.35197	0.34826
.....										
1.8	0.03593	0.03515	0.03438	0.03362	0.03288	0.03216	0.03144	0.03074	0.03005	0.02937
1.9	0.02872	0.02807	0.02743	0.02680	0.02619	0.02559	0.02500	0.02442	0.02385	0.02329
2.0	0.02275	0.02222	0.02169	0.02118	0.02068	0.02018	0.01970	0.01923	0.01876	0.01830
2.1	0.01786	0.01743	0.01700	0.01659	0.01618	0.01578	0.01539	0.01500	0.01463	0.01426

例) $z=2.00$ のとき


z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48404	0.48005	0.47606	0.47207	0.46808	0.46409
0.1	0.46017	0.45620	0.45224	0.44828	0.44431	0.44035	0.43639	0.43243	0.42847	0.42451
0.2	0.42074	0.41683	0.41291	0.40899	0.40507	0.40115	0.39723	0.39331	0.38939	0.38547
0.3	0.38209	0.37828	0.37445	0.37063	0.36681	0.36298	0.35916	0.35534	0.35152	0.34769
1.8	0.03593	0.03515	0.03438	0.03362	0.03288	0.03216	0.03144	0.03074	0.03005	0.02936
1.9	0.02872	0.02801	0.02731	0.02660	0.02590	0.02519	0.02449	0.02379	0.02309	0.02239
2.0	0.02275	0.02222	0.02169	0.02118	0.02068	0.02018	0.01970	0.01923	0.01876	0.01830
2.1	0.01786	0.01743	0.01700	0.01659	0.01618	0.01578	0.01539	0.01500	0.01463	0.01426

この値が $z=2.00$ のときの
上側確率

$$\Pr(Z > 2.00) = 0.02275$$

例) $z=5.00$ のとき



- 標準正規分布表には $z=3.09$ までしかない...
 - もっとも近い値で計算する
 - $z=3.09$ の確率をみると
0.00100とものすごく小さい値
 - $z>3.09$ のときはどんどん0に近似するので
ほぼ0とみなすことが多い
- 教科書によってはさらに細かい表まであることもある



**$z>3.09$ は
ほぼゼロ**

例) $z=-2.00$ のとき


- もし z がマイナスの値だったら...?
 - 左右対称
 - 面積全体は1
(確率の合計は1)
 - つまり、絶対値の上側確率を計算して1から引けば求めることができる



例) $-1.00 < z < 1.00$ のとき

- $\Pr(-1.00 < Z < 1.00)$

正規分布は左右対称




例) $-1.00 < z < 1.00$ のとき

- $\Pr(-1.00 < Z < 1.00)$

正規分布は左右対称

両端の白い部分の面積は同じ




例) $-1.00 < z < 1.00$ のとき

- $\Pr(-1.00 < Z < 1.00)$

正規分布は左右対称

両端の白い部分の面積は同じ

確率の合計は1





求めた面積を2倍にして
1から引く


$$\begin{aligned} \Pr(-1.00 < z < 1.00) \\ = 1 - (2 \times 0.15866) = 0.68 \end{aligned}$$

p86

z	0.00	0.01
.		
.		
.		
0.8	0.21186	0.20897
0.9	0.18406	0.18141
1.0	0.15866	0.15625
1.1	0.13567	0.13350



z	0.05	0.06
.		
.		
.		
1.6	0.04947	0.04846
1.7	0.04006	0.03920
1.8	0.03216	0.03144
1.9	0.02559	0.02500



$$\Pr(-1.96 < Z < 1.96) = 1 - 2 \times 0.02500 \approx 0.95$$

図 7-2 標準正規分布表に基づく確率計算

p86 例題7-1



例題 7-1

標本平均の分布に関する確率計算


第2章例題2-1(25頁)では、母集団2万人における来店頻度の平均値と標準偏差の計算を行いました。常連客の1週間の来店頻度に関する平均値は2.00、標準偏差は1.41(分散は1.976)でした。このような母集団から標本を抽出した際の標本平均の分布について考えてみましょう。

母集団の分布は $E(X_i)=2.00$, $Var(X_i)=1.976$ と想定することができますので、中心極限定理から、標本平均 $\bar{X}$ の分布は、平均2.00、分散 $\frac{1.976}{n}$ の正規分布です。標本の大きさ n が200のときに、母平均±0.1の範囲内に標本平均 $\bar{X}$ が含まれる確率 $Pr(|\bar{X}-\mu_X|<0.1)$ を計算します。まずは、標本平均 $\bar{X}$ が母平均2.00から0.1だけ大きい値となる場合 ($\bar{X}=2.00+0.1=2.10$) に対応する Z の値を求めます。

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu_X}{\sqrt{\frac{\sigma_X^2}{n}}} = \frac{2.10 - 2.00}{\sqrt{\frac{1.976}{200}}} \approx 1.01$$

$z=1.01$ のとき、標準正規分布表(162頁, 付録2)から上側確率は $Pr(Z>1.01)=0.15625$ となり、 $Pr(-1.01<Z<1.01)=1-2\times0.15625\approx0.69$ です。

この確率計算は、標本として200人抽出したときの標本平均を確率で評価していることになります。母平均±0.1の範囲内に標本平均 $\bar{X}$ が含まれる確率は0.69ですから、標本調査の結果が母平均±0.1の範囲内に含まれない確率は0.31もあることがわかります。



p86 例題7-1

- 母集団2万人の来店頻度
 - 平均 2.00
 - 標準偏差 1.41
 - 分散 $1.41^2 = 1.976$
- 標本平均 $\bar{X}$ の分布 $\Rightarrow$ 正規分布
 - 平均 2.00
 - 分散 $\frac{1.976}{n}$
- 標本の大きさが200のときに
母平均 ± 0.1 の範囲内に
標本平均が含まれる確率を求める

p86 例題7-1

- 母平均 2.00
- 母分散 1.976
- 標本数 200
- 標本平均が母平均より0.1大きい場合のZ

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu_X}{\sqrt{\frac{\sigma_X^2}{n}}} = \frac{\text{標本平均} - \text{母平均}}{\sqrt{\frac{\text{母分散}}{\text{標本数}}}}$$

p86 例題7-1

- 母平均 2.00
- 母分散 1.976
- 標本数 200
- 標本平均が母平均より0.1大きい場合のZ

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu_X}{\sqrt{\frac{\sigma_X^2}{n}}} = \frac{2.10 - 2.00}{\sqrt{\frac{1.976}{200}}} = 1.01$$

p86 例題7-1

- 母平均 2.00
- 母分散 1.976
- 標本数 200
- $Z = 1.01$ のときの上側確率を
標準正規分布表から求める
- $Pr(-1.01 < Z < 1.01)$ を求める

標準正規分布表でLook up→

$$Pr(-1.01 < Z < 1.01) = 1 - 2 * 0.15625 = 0.69$$

標準正規分布表

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.50000	0.49601	0.49202	0.48803	0.48405	0.48006	0.47608	0.47210	0.46812	0.46414
0.1	0.46017	0.45620	0.45224	0.44828	0.44433	0.44038	0.43644	0.43251	0.42858	0.42465
0.2	0.42074	0.41683	0.41294	0.40905	0.40517	0.40129	0.39743	0.39358	0.38974	0.38591
0.3	0.38209	0.37828	0.37448	0.37070	0.36693	0.36317	0.35942	0.35569	0.35197	0.34827
0.4	0.34458	0.34090	0.33724	0.33360	0.32997	0.32636	0.32276	0.31918	0.31561	0.31207
0.5	0.30854	0.30503	0.30153	0.29806	0.29460	0.29116	0.28774	0.28434	0.28096	0.27760
0.6	0.27425	0.27093	0.26763	0.26435	0.26109	0.25785	0.25463	0.25143	0.24825	0.24510
0.7	0.24196	0.23885	0.23576	0.23270	0.22965	0.22663	0.22363	0.22065	0.21770	0.21476
0.8	0.21186	0.20897	0.20611	0.20327	0.20045	0.19766	0.19489	0.19215	0.18943	0.18673
0.9	0.18406	0.18141	0.17879	0.17619	0.17361	0.17106	0.16853	0.16602	0.16354	0.16109
1.0	0.15866	0.15625	0.15386	0.15151	0.14917	0.14686	0.14457	0.14231	0.14007	0.13786
1.1	0.13567	0.13350	0.13136	0.12924	0.12714	0.12507	0.12302	0.12100	0.11900	0.11702
1.2	0.11507	0.11314	0.11123	0.10935	0.10749	0.10565	0.10383	0.10204	0.10027	0.09853
1.3	0.09680	0.09510	0.09342	0.09176	0.09012	0.08851	0.08691	0.08534	0.08379	0.08226
1.4	0.08076	0.07927	0.07780	0.07636	0.07493	0.07353	0.07215	0.07078	0.06944	0.06811
1.5	0.06681	0.06552	0.06426	0.06301	0.06178	0.06057	0.05938	0.05821	0.05705	0.05592
1.6	0.05480	0.05370	0.05262	0.05155	0.05050	0.04947	0.04846	0.04746	0.04648	0.04551
1.7	0.04457	0.04363	0.04272	0.04182	0.04093	0.04006	0.03920	0.03836	0.03754	0.03673
1.8	0.03593	0.03515	0.03438	0.03362	0.03288	0.03216	0.03144	0.03074	0.03005	0.02938
1.9	0.02872	0.02807	0.02743	0.02680	0.02619	0.02559	0.02500	0.02442	0.02385	0.02330
2.0	0.02275	0.02222	0.02169	0.02118	0.02068	0.02018	0.01970	0.01923	0.01876	0.01831

So what does this mean?

200人のサンプルを抽出した場合、
標本平均が 2.00 ± 0.1 (1.90から2.10) の範囲に入る確率は

約69%

p87 問題7-1



問題 7-1

標本の大きさ n を大きくしたときの標本平均の状況

例題 7-1 の状況よりも調査精度を高めるために、標本の大きさを 1,000 にすることを考えます。母平均 ± 0.1 の範囲内に標本平均 $\bar{X}$ が含まれる確率 $\Pr(|\bar{X} - \mu_X| < 0.1)$ を計算してください。図 7-3 に問題状況を表現します。例題 7-1 とは標本の大きさ n が異なるだけで、その他の数値等は同じように計算できます。

- 標本数が $n=1000$ のとき
母平均 ± 0.1 の範囲内に
標本平均が含まれる確率を求めよ

p87 問題7-1


- 標本数が $n=1000$ のとき
母平均 ± 0.1 の範囲内に
標本平均が含まれる確率を求めよ

$$Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu_X}{\sqrt{\frac{\sigma_X^2}{n}}} = \frac{2.10 - 2.00}{\sqrt{\frac{1.976}{1000}}} \approx 2.25$$

標準正規分布表でLook

up →

$$Pr(-2.25 < Z < 2.25) =$$



標準正規分布曲線を描いてラベルを付ける

1000人のサンプルを抽出した場合、
標本平均が 2.00 ± 0.1 (1.90から2.10) の範囲に入る確率は

約97.6%

カイ二乗分布



Karl Pearson (1857-1936)

- English mathematician
- big boss of stats
- but... also one of the fathers of eugenics 「優生学」

「優生学」

“ Eugenics is the scientifically erroneous and immoral theory of “racial improvement” and “planned breeding,” which gained popularity during the early 20th century. Eugenicists worldwide believed that they could perfect human beings and eliminate so-called social ills through genetics and heredity. ”

優生学とは、20世紀初頭に人気を博した「人種改良」と「計画的繁殖」に関する科学的に誤った不道德な理論です。世界中の優生学者は、遺伝学と遺伝によって人間を完璧にし、いわゆる社会的悪を排除できると信じていました。

(1) カイ二乗分布の定義

カイ二乗分布の定義


- χ^2 分布 (chi-squared distribution)
 - 自由度 ν のカイ二乗分布
 - 標準正規分布 $N(0,1)$ にしたがう独立な ν 個の確率変数 X_i の平方和に関する確率分布
 - $\chi^2(\nu) \quad X_1^2 + X_2^2 + X_3^2 + \dots + X_\nu^2$
 - 平均値 ν 自由度と等しい
 - 分散 2ν 自由度の2倍
 - 自由度が小さいとき左右非対称
 - 自由度が大きくなるにつれて左右対称に変化
 - 自由度の値が大きいつきに正規分布に近似

自由度 degree of freedom


$$n - 1$$

- 自由に動くことのできる変数の数
- 与えられた等式（条件）の分だけ減る
 - 例 データ（4, x, 1, 1） xは未知
条件 平均値は2
 $\Rightarrow 4+x+1+1=2 \times 4$
 - データの個数n個に
平均値を与える（条件1つ）と
データ **n-1**個がわかれば、すべてのデータがわかる
（残りの1つは必然的に決まる）

自由度10のカイ二乗分布



自由度10～50のカイ二乗分布



平方和の分解

Z^2 (標本平均 $\bar{X}$ を標準化した Z の平方)

– 自由度1のカイ二乗分布にしたがう

$$\frac{\sum (X_i - \mu_X)^2}{\sigma_X^2} = \frac{\sum (X_i - \bar{X})^2}{\sigma_X^2} + \frac{n(\bar{X} - \mu_X)^2}{\sigma_X^2}$$

自由度n
のカイ二乗分布

自由度n-1
のカイ二乗分布

自由度1
のカイ二乗分布

教科書ではわかりにくいので...

カイ二乗分析はなんで使う
の？



現在の学生数

2,621名

男子：1,605名

女子：1,016名

(2024年5月現在)

60 : 40

 男子 : 女子 

本当かな？では、無作為で20人の学生を抽出したら...



11 : 9

本当かな？では、無作為で20人の学生を抽出したら...



12 : 8

本当かな？では、無作為で20人の学生を抽出したら...



13 : 7

本当かな？では、無作為で20人の学生を抽出したら...



14 : 6

本当かな？では、無作為で20人の学生を抽出したら...



15 : 5

なんとなく、直感（gut feeling）では解決できない...

カイ二乗検定

Chi Squared Test

集めたデータ ↔ 予測データ

H_0 帰無仮説 = 60 : 40

帰無仮説を棄却（ききやく）できるでしょうか？

Can we reject the null hypothesis?

In other words...

このクラスは、母集団（全校の比率）と比べて、有意に、
そして統計的に異なると言えるのか？

Is this class significantly, and statistically different from the population?

ではカイ二乗を求めよう：

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- χ^2 はカイ二乗検定統計量
- O_i はカテゴリ i の観測度数 (Observed)
- E_i はカテゴリ i の期待度数 (Expected)

自由度は？

$$n - 1$$

この場合の「 n 」はカテゴリーの数{男子,女子}が2なので自由度は1である


$$\text{Degree of Freedom (DF)} = 2 - 1 = 1$$

カイ二乗分布表

カイ二乗分布のパーセント点

カイ二乗分布表では、自由度 ν と上側確率 α に対応したカイ二乗分布 $\chi^2(\nu)$ のパーセント点 $\chi^2_{\alpha}(\nu)$ を表す。

たとえば、自由度 $\nu=5$ 、上側確率 $\alpha=0.025$ のとき、表側の 5 と表頭の 0.025 との交差点である 12.8325 が 2.5 パーセント点 $\chi^2_{0.025}(5)=12.8325$ となる。



ν	α	0.995	0.990	0.975	0.950	0.050	0.025	0.010	0.005
1		0.0000	0.0002	0.0010	0.0039	3.8415	5.0239	6.6349	7.8794
2		0.0100	0.0201	0.0506	0.1026	5.9915	7.3778	9.2103	10.5966
3		0.0717	0.1148	0.2158	0.3518	7.8147	9.3484	11.3449	12.8382
4		0.2070	0.2971	0.4844	0.7107	9.4877	11.1433	13.2767	14.8603
5		0.4117	0.5543	0.8312	1.1455	11.0705	12.8325	15.0863	16.7496
6		0.6757	0.8721	1.2373	1.6354	12.5916	14.4494	16.8119	18.5476
7		0.9893	1.2390	1.6899	2.1673	14.0671	16.0128	18.4753	20.2777
8		1.3444	1.6465	2.1797	2.7326	15.5073	17.5345	20.0902	21.9550
9		1.7349	2.0879	2.7004	3.3251	16.9190	19.0228	21.6660	23.5894
10		2.1559	2.5582	3.2470	3.9403	18.3070	20.4832	23.2093	25.1882

n=1

	O	E	O-E	(O-E) ²	(O-E) ² /E
男子	0	0	0	0	#DIV/0!
女子	0	0	0	0	#DIV/0!
	0			χ^2 (カイ二乗)→	#DIV/0!

Here



X^2

$> \cdot <$



確率 0.05 の値

従って、帰無仮説は棄却 できる・できない



コアラのマーチ「激レアキャラ」は都市伝説？

365種類の絵柄は全て同じ数だけ作ってると言われている。本当かな？

<https://www.lotte.co.jp/products/brand/koala/book/>

ご当地コアラ(51)

- 51種類

- 出る確率は $\frac{51}{365}$ or **14%**



スポーツコアラ(47)

- 47種類

- 出る確率は $\frac{47}{365}$ or **13%**



おあそび&おでかけ （29種類）

- 29種類
- 出る確率は $\frac{29}{365}$ or **8%**



お仕事 (28種類)

- 28種類
- 出る確率は $\frac{28}{365}$ or 8%



H_0 帰無仮説

コアラのご当地・スポーツ・仕事・おあそび&おでかけ・その他の比率
は

51 : 47 : 29 : 28 : 210

14% : 13% : 8% : 8% : 58%

である

帰無仮説を棄却できるでしょうか?

Can we reject the null hypothesis?

- 自由度(DF) : $5 - 1 = 4$

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

n=4

	Observed (O)	Expected (E)	O-E	(O-E) ²	(O-E) ² /E
ご当地コアラ (14%)	0	0	0	0	#DIV/0!
スポーツコアラ (13%)	0	0	0	0	#DIV/0!
仕事コアラ (8%)	0	0	0	0	#DIV/0!
おあそびコアラ (8%)	0	0	0	0	#DIV/0!
その他 (58%)	0	0	0	0	#DIV/0!
	0			χ ² (カイ二乗)→	#DIV/0!


Enter!

カイ二乗分布表

カイ二乗分布のパーセント点

カイ二乗分布表では、自由度 ν と上側確率 α に対応したカイ二乗分布 $\chi^2(\nu)$ のパーセント点 $\chi^2_{\alpha}(\nu)$ を表す。

たとえば、自由度 $\nu=5$ 、上側確率 $\alpha=0.025$ のとき、表側の 5 と表頭の 0.025 との交差点である 12.8325 が 2.5 パーセント点 $\chi^2_{0.025}(5)=12.8325$ となる。



ν	α	0.995	0.990	0.975	0.950	0.050	0.025	0.010	0.005
1		0.0000	0.0002	0.0010	0.0039	3.8415	5.0239	6.6349	7.8794
2		0.0100	0.0201	0.0506	0.1026	5.9915	7.3778	9.2103	10.5966
3		0.0717	0.1148	0.2158	0.3518	7.8147	9.3484	11.3449	12.8382
4		0.2070	0.2971	0.4844	0.7107	9.4877	11.1433	13.2767	14.8603
5		0.4117	0.5543	0.8312	1.1455	11.0705	12.8325	15.0863	16.7496
6		0.6757	0.8721	1.2373	1.6354	12.5916	14.4494	16.8119	18.5476
7		0.9893	1.2390	1.6899	2.1673	14.0671	16.0128	18.4753	20.2777
8		1.3444	1.6465	2.1797	2.7326	15.5073	17.5345	20.0902	21.9550
9		1.7349	2.0879	2.7004	3.3251	16.9190	19.0228	21.6660	23.5894
10		2.1559	2.5582	3.2470	3.9403	18.3070	20.4832	23.2093	25.1882