

Sigma:総和 (sum) 、全ての値の足す

データの最後の番号

アバー (x bar) : 平均値

データの実際

統計学B

Week 8


データの数の分で割る

Sigmaの中の変数の宣言


データの最初の番号



The Galton Board



- Sir Francis Galton (1822-1911)
- British mathematician
- invented the "Galton Board"
- regression to the mean, or "reversion to mediocrity"
- 回歸先平均
(ex: test scores, heights, sports)



Source: YouTube

$n=4$


$n=20$

$n=100$

平均の平均

中心極限定理

Central Limit Theorem



ように...


The Central Limit Theorem says that if you take a lot of averages from random samples, those averages will look like a bell curve, no matter how the original data looks!

中心極限定理とは、たくさんのデータをランダムに平均すると、その平均がどんなデータでもベルカーブ（正規分布）に近づくということです！



Let's prove it

Google 「グーグルサイコロ」



Student	Roll 1	Roll 2	Roll 3	Roll 4	Sample Mean (n=4)
Student 1					#DIV/0!
Student 2					#DIV/0!
Student 3					#DIV/0!
Student 4					#DIV/0!
Student 5					#DIV/0!
Student 6					#DIV/0!
Student 7					#DIV/0!
Student 8					#DIV/0!
Student 9					#DIV/0!
Student 10					#DIV/0!
Student 11					#DIV/0!

google sheet

標本平均の分布 p71

the sampling distribution of the sample mean

クイズ 6 (p70)

クイズ 6 どちらの標準偏差の値が小さいのか？

高校2年生男子160名の体力測定50m走の記録について、散らばりの統計量である標準偏差を計算します。50m走は4人1組で実施して、個人別のタイムを計測しました。記録簿には個人別の記録のほかに、4人1組ごとの組別平均値とクラス別平均値も計算されています。1クラスの男子は20名、8クラス合計で160名です。

いま、平均値を統計データとして考えるならば、50m走の組別平均値は40組分あり、クラス別平均値は8クラス分あります。組別平均値を40個の統計データとして、さらにそれらの平均値を計算すると高校2年生男子160名全体の平均値と一致します。同様にクラス別平均値に関する平均値も全体の平均値に一致します。

それでは、統計データの散らばりを表す標準偏差はどのような値になるのでしょうか。平均値は一致しても、散らばりの統計量が同じ値をとることはありません。以下のA、Bの標準偏差のうち小さい値となるのはどちらでしょうか（解答は73頁）。

A：組別平均値（40個）を
統計データとした標準偏差

B：クラス別平均値（8個）を
統計データとした標準偏差

50m 走 (秒)	1 コース	2 コース	3 コース	4 コース	組別 平均値	クラス別 平均値
1 組	6.4	8.0	7.0	8.4	7.450	7.260
2 組	8.0	5.8	7.6	7.0	7.100	
3 組	6.6	7.3	6.7	7.4	7.000	
4 組	6.7	7.1	7.4	7.9	7.275	
5 組	7.4	6.9	7.6	8.0	7.475	
6 組	7.4	7.3	7.6	7.3	7.400	7.460
7 組	7.9	8.4	7.3	7.2	7.700	
8 組	7.2	7.7	8.1	6.8	7.450	

A：組別平均値（40 個）を
統計データとした標準偏差

B：クラス別平均値（8 個）を
統計データとした標準偏差

50m 走 (秒)	1 コース	2 コース	3 コース	4 コース	組別 平均値	クラス別 平均値
1 組	6.4	8.0	7.0	8.4	7.450	7.260
2 組	8.0	5.8	7.6	7.0	7.100	
3 組	6.6	7.3	6.7	7.4	7.000	
4 組	6.7	7.1	7.4	7.9	7.275	
5 組	7.4	6.9	7.6	8.0	7.475	
6 組	7.4	7.3	7.6	7.3	7.400	7.460
7 組	7.9	8.4	7.3	7.2	7.700	
8 組	7.2	7.7	8.1	6.8	7.450	

$n=40$
 $n=4$
 $n=28$
 $n=8$



例題 6-1

標本平均の分布 40 rows

クイズ 6 では、組別平均値を統計データとした標準偏差と、クラス別平均値を統計データとした標準偏差とを比較しました。これらは標本平均の分布に関する標準偏差といえます。図 6-3 に、高校 2 年生男子 160 名の体力測定 50 m 走の記録に加えて、標本平均に該当する組別平均値とクラス別平均値を度数分布で表します。図 6-3 における 3 つの度数分布から、クラス別平均値の分布 (c) は、組別平均値の分布 (b) に比べて散らばりの小さいことがわかります。また、標本平均の標準偏差 $\frac{\sigma_x}{\sqrt{n}}$ の分母は $\sqrt{n}$ であるので、理論的にも、クラス別平均値の標準偏差 ($n=20$) の方が組別平均値の標準偏差 ($n=4$) よりも小さくなります。厳密に言えば、クイズ 6 は有限母集団の状況を表しているため、標本平均の標準偏差は $\sqrt{\frac{N-n}{N-1}} \sqrt{\frac{\sigma_x^2}{n}}$ となります (77 頁コラム参照)。










図 6-3 高校 2 年生男子 160 名の体力測定 50 m 走の記録と組別平均値、クラス別平均値

Simulate in python





<https://youtu.be/zeJD6dqJ5lo?si=EVLiaDlad-7XeVHp&t=369>

(2) 標本平均の分布 p72

the sampling distribution of the sample mean




図 6-2 複数回の標本抽出による標本平均

標本平均の分布

- 標本における観測値 $x_1, x_2, \dots, x_n$ を確率変数として $X_1, X_2, \dots, X_n$ とする
 - 関数 $g(X_1, X_2, \dots, X_n)$
- 標本平均

$$\bar{X} = \frac{1}{n} \sum X_i$$

- 確率変数の関数
 - 標本平均自体が確率変数であるといえる

(3) 標本平均 $\bar{X}$ の平均値と分散 p73

Mean and Variance of the Sample Mean $\bar{X}$

$$E(\bar{X}) = \mu_X, \quad \text{Var}(\bar{X}) = \frac{\sigma_X^2}{n}$$

Handwritten red annotations: μ under μ_X and $\frac{\sigma_X^2}{n}$ under the variance formula.

定理 11 ★★★★★




標本平均 $\bar{X}$ の平均値

- 母集団 X
 - 母平均 μ_X
 - 母分散 σ_X^2
- 期待値として表すと
 - 平均 $E(X) = \mu_X$
 - 分散 $Var(X) = \sigma_X^2$
- 平均値 $E(\bar{X}) = \mu_X$
 - 母平均と同じになる
 - つまり、平均的に標本平均($\bar{X}$)は母集団の平均 μ と等しいです。
 - on average, the sample mean ($\bar{X}$) is equal to the population mean (μ)

標本平均 $\bar{X}$ の分散

$$Var(\bar{X}) = \frac{\sigma_X^2}{n}$$

- 分散
 - 母分散の $\frac{1}{n}$ 倍
- ここで：
 - σ^2 は母集団の分散です。
 - n は標本のサイズです。



この数式から、標本平均 $\bar{X}$ の分散は標本サイズ (n) が増加するにつれて
減少することがわかります。つまり、より大きな標本は、母集団の平均
 μ に近い標本平均を生成する傾向があります。

標本平均 $\bar{X}$ の標準偏差

- 分散 $Var(\bar{X}) = \frac{\sigma_X^2}{n}$ なので、
標準偏差は

$$\text{標準偏差} = \frac{\sigma_X}{\sqrt{n}}$$

p76 問題6-1




問題 6-1

標本調査の精度

無限母集団から標本を無作為抽出して調査を行ったことを想定します。標本の大きさ n が 200 のとき、標本平均の標準偏差は理論的には $\frac{\sigma_x}{\sqrt{200}}$ です。いま、調査の規模を 10 倍、すなわち標本の大きさ n を 2,000 にすることを考えます。このようなとき、調査の精度は 10 倍になるでしょうか。標本平均の標準偏差の大きさを調査精度として考えてみましょう。標本平均の標準偏差は、標本の大きさ n が 200 のときに比べて何割程度になりますか。標準偏差の大きさを計算してください。もしも調査精度が 10 倍になるなら、標準偏差は 1 割の大きさになるはずです。

p76 問題6-1

【難】 標本調査の精度

- 無限母集団から
標本を無作為抽出して調査を行う。
 - 標本の大きさ $n=200$ のとき
標本平均の標準偏差は理論的には $\frac{\sigma_x}{\sqrt{200}}$

 - 調査の規模を10倍 ($n=2000$) にしたとき
調査の精度は10倍になるか？
 - 標本平均の標準偏差の大きさを調査精度と考える
 - 標本平均の標準偏差は $n=200$ のときの何割程度になるか
 - もしも調査の精度が10倍になるなら
 - 標本平均の標準偏差（ばらつき）は0.1程度になるはず

p76 問題6-1

- 標本の大きさを10倍にしても調査の精度は10倍にはならない
 - 標準偏差は**1/10**にはならない

$$\frac{\sigma_X}{\sqrt{200}} : \frac{\sigma_X}{\sqrt{2000}} = 1 : \frac{1}{\sqrt{10}} = 1 : 0.316$$

精度は標準誤差の逆数で表されます。標準誤差が 0.316 倍に減少すると、精度は次のように増加します：

$$\text{新しい精度} = \frac{1}{0.316} \approx 3.16$$

つまり、標本サイズが 200 から 2000 に増加した場合、精度は約 **3.16** 倍 向上します。

正規分布 (normal distribution)

連続確率変数 X の確率密度関数 $f(x)$ が

$$f(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left\{-\frac{(x-\mu_X)^2}{2\sigma_X^2}\right\}$$


となるときの X の確率分布

- Mean and standard deviation


$X \sim N(\mu_X, \sigma_X^2)$ 平均と標準偏差

- Bell Shape

平均を中心として左右対称の連続確率分布




正規分布 (normal distribution)




- $X \sim N(\mu_X, \sigma_X^2)$
- 平均を中心として左右対称の連続確率分布

正規分布 (normal distribution)



- $X \sim N(\mu_X, \sigma_X^2)$
- 平均を中心として左右対称の連続確率分布

正規分布 (normal distribution)



- $X \sim N(\mu_X, \sigma_X^2)$
- 平均を中心として左右対称の連続確率分布


In class review sheet

Practice Exercise

身長


●男子

生徒数	平均値	標準偏差
452,092人	161.09cm	7.41



●女子

生徒数	平均値	標準偏差
432,904人	154.94cm	5.37



スポーツ庁の令和4年度全国体力・運動能力、運動習慣等調査結果


無作為で 10、30、50、人の女子中学生を選出したら、

平均身長が153cmから156cmの間にある確率は？

$$Pr(153cm > \bar{X} > 156cm)$$


●女子

生徒数	平均値	標準偏差
432,904人	154.94cm	5.37



標準化する（Z値を求める）

図表 2 正規分布の特徴



Remember? 母集団の場合

$$Z = \frac{X - \mu}{\sigma}$$

But when you are using a 標本

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

1. General Formula:

$$SE = \frac{\sigma}{\sqrt{n}}$$

2. SE for $n = 10$:

$$SE_{10} = \frac{5.37}{\sqrt{10}} = \frac{5.37}{3.162} \approx 1.70$$

3. SE for $n = 30$:

$$SE_{30} = \frac{5.37}{\sqrt{30}} = \frac{5.37}{5.477} \approx 0.98$$

4. SE for $n = 50$:

$$SE_{50} = \frac{5.37}{\sqrt{50}} = \frac{5.37}{7.071} \approx 0.76$$

$$Z = \frac{\bar{X} - \mu}{SE}$$

For n = 10:

$$Z_{153} = \frac{153 - 154.94}{1.70} = \frac{-1.94}{1.70} \approx -1.14$$

$$Z_{156} = \frac{156 - 154.94}{1.70} = \frac{1.06}{1.70} \approx 0.62$$

For n = 30:

$$Z_{153} = \frac{153 - 154.94}{0.98} = \frac{-1.94}{0.98} \approx -1.98$$

$$Z_{156} = \frac{156 - 154.94}{0.98} = \frac{1.06}{0.98} \approx 1.08$$

For n = 50:

$$Z_{153} = \frac{153 - 154.94}{0.76} = \frac{-1.94}{0.76} \approx -2.55$$

$$Z_{156} = \frac{156 - 154.94}{0.76} = \frac{1.06}{0.76} \approx 1.39$$

$$P(153 \leq \bar{X} \leq 156) = P(Z_{156}) - P(Z_{153})$$

For $n = 10$

$$SE_{10} = \frac{5.37}{\sqrt{10}} = \frac{5.37}{3.162} \approx 1.70$$

$$Z_{153} = \frac{153 - 154.94}{1.70} = \frac{-1.94}{1.70} \approx -1.14$$

$$Z_{156} = \frac{156 - 154.94}{1.70} = \frac{1.06}{1.70} \approx 0.62$$

$$P(Z_{153}) \approx 0.1271, P(Z_{156}) \approx 0.7324$$

$$P(153 \leq \bar{X} \leq 156) = P(Z_{156}) - P(Z_{153}) = 0.7324 - 0.1271 = 0.6053 \text{ (60.5\%)}$$

For $n = 30$

$$SE_{30} = \frac{5.37}{\sqrt{30}} = \frac{5.37}{5.477} \approx 0.98$$

$$Z_{153} = \frac{153 - 154.94}{0.98} = \frac{-1.94}{0.98} \approx -1.98$$

$$Z_{156} = \frac{156 - 154.94}{0.98} = \frac{1.06}{0.98} \approx 1.08$$

$$P(Z_{153}) \approx 0.0239, P(Z_{156}) \approx 0.8599$$

$$P(153 \leq \bar{X} \leq 156) = P(Z_{156}) - P(Z_{153}) = 0.8599 - 0.0239 = 0.8360 \text{ (83.6\%)}$$

For $n = 50$

$$SE_{50} = \frac{5.37}{\sqrt{50}} = \frac{5.37}{7.071} \approx 0.76$$

$$Z_{153} = \frac{153 - 154.94}{0.76} = \frac{-1.94}{0.76} \approx -2.55$$


$$Z_{156} = \frac{156 - 154.94}{0.76} = \frac{1.06}{0.76} \approx 1.39$$

$$P(Z_{153}) \approx 0.0054, P(Z_{156}) \approx 0.9177$$

$$P(153 \leq \bar{X} \leq 156) = P(Z_{156}) - P(Z_{153}) = 0.9177 - 0.0054 = 0.9123 \text{ (91.2\%)}$$

n	SE	$P(153 \leq \bar{X} \leq 156)$
10	1.70	60.53%
30	0.98	83.60%
50	0.76	91.23%

図表 2 正規分布の特徴



上の表に153cmと156cmのZ値の範囲を示して塗りつぶす



全国の中学生の男子の50m走の平均値は 8.06、
標準偏差は 1.07 である。

無作為で 50 人の男子中学生を選出したら、
その 50 人の平均値が 6秒 から 7秒 の間にある確率は？

第6章のまとめ

- 標本の観測値 x_i を確率変数 X_i として表す
 - 標本平均 $\bar{X}$
 - 標本平均に関する平均値 $E(\bar{X}) = \mu_X$
 - 標本平均に関する分散 $Var(\bar{X}) = \frac{\sigma_X^2}{n}$
- 標本の大きさ n を大きくしたとき
標本平均は母平均に近づく
- 中心極限定理
 - 母集団の分布がどのような分布であっても
無作為抽出した標本における標本平均は
標本の大きさ n が大きいときに正規分布にしたがう
- 正規分布
 - 中心は平均
 - 左右対称
 - 連続確率分布