

MLB

NCAAF

NHL

Soccer

WNBA

More Sports

統計学B

Week 8



Golden State Warriors • #30 • Guard

Follow

標本不偏分散 p126

$$\hat{\sigma}_x^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$$



NFLNBA[^]MLBNCAAFNHL[^]SoccerWNBAMore Sports



STEPHEN
CURRY

 Golden State Warriors • #30 • Guard

Follow

HT/WT6' 2", 185 lbs

BIRTHDATE3/14/1988 (37)

COLLEGEDavidson

DRAFT INFO2009: Rd 1, Pk 7 (GS)

STATUS● Active

https://www.espn.com/nba/player/_/id/3975/stephen-curry

PPG			APG			3P%			FG%			
27.4			3.7			38.1			45.8			
SPLITS	GP	MIN	FG%	3P%	FT%	REB	AST	BLK	STL	PF	TO	PTS
L10	7	30.7	42.9	35.4	90.0	3.6	2.7	0.1	1.1	2.7	3.0	27.7
Road	8	30.1	45.1	36.6	91.2	3.5	2.9	0.4	1.4	2.5	3.1	28.0

Stats
[See All](#)

STATS	GP	MIN	FG%	3P%	FT%	REB	AST	BLK	STL	PF	TO	PTS
Regular Season	12	30.6	45.8	38.1	93.3	3.7	3.7	0.4	1.4	2.3	2.7	27.4
Career	1038	34.1	47.1	42.3	91.2	4.7	6.3	0.3	1.5	2.3	3.1	24.8

Recent Games
[See All](#)

DATE	OPP	RESULT	MIN	FG%	3P%	FT%	REB	AST	BLK	STL	PF	TO	PTS
Mon 11/17	@  NO	W 124-106	28	18.2	16.7	80.0	5	3	0	0	3	4	9
Sat 11/15	@  SA	W 109-108	36	61.5	52.9	100.0	4	2	0	2	2	3	49
NBA CUP - GROUP PLAY													
Thu 11/13	@  SA	W 125-120	34	52.0	31.3	93.8	5	5	0	2	2	1	46
Wed 11/12	@  OKC	L 126-102	20	30.8	20.0	66.7	1	0	0	1	5	1	11
Wed 11/5	vs  PHX	W 118-107	34	39.1	41.7	100.0	4	3	1	1	3	2	28

Steph Curry's Last 5 Games

Game	Score
1	9
2	49
3	46
4	11
5	28

$$\bar{X} = \frac{9+49+46+11+28}{5} = 28.6$$

$$\begin{aligned}
\hat{\sigma}_x^2 &= \frac{1}{n-1} \sum (X_i - \bar{X})^2 \\
&= \frac{(9 - 28.6)^2 + (49 - 28.6)^2 + (46 - 28.6)^2 + (11 - 28.6)^2 + (28 - 28.6)^2}{4} \\
&= \frac{384.16 + 416.16 + 302.76 + 309.76 + 0.36}{4} \\
&= \frac{1413.2}{4} = 353.3
\end{aligned}$$

Game	Score (Xi)	Mean ($\bar{X}$)	$X_i - \bar{X}$	$(X_i - \bar{X})^2$
1	9	28.6	-19.6	384.16
2	49	28.6	20.4	416.16
3	46	28.6	17.4	302.76
4	11	28.6	-17.6	309.76
5	28	28.6	-0.6	0.36
Sum	142			1413.2
Sample variance ($1/(n-1) \Sigma$)				353.3

In other words, Steph Curry's sample variance over the last 5 games is 353.3 points squared.

クラス内活動：好きな選手の標本分散 を計算しよう

ステップ1：選手を選ぶ

ESPNから好きなNBA選手の過去5試合のスコアデータを探してください。

選手名： _____

Game	Score
1	
2	
3	
4	
5	

ステップ2：平均値を計算する

$$\bar{X} = \frac{\quad}{5} =$$

ステップ3：分散表を完成させる

Game	Score (X_i)	Mean ($\bar{X}$)	$X_i - \bar{X}$	$(X_i - \bar{X})^2$
1				
2				
3				
4				
5				
合計				

ステップ4：標本分散を計算する

$$\hat{\sigma}_x^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2 = \frac{4}{4} =$$

結果： 標本分散は _____ ポイント²

t分布

William Sealy Gosset



William Sealy Gosset (aka *Student*) in 1908
(age 32)

Born	13 June 1876 Canterbury , Kent, England
Died	16 October 1937 (aged 61) Beaconsfield , Buckinghamshire, England
Other names	Student
Alma mater	New College, Oxford , Winchester College
Known for	Student's t-distribution, statistical significance, design of experiments, Monte Carlo method, quality control, Modern synthesis, agricultural economics, econometrics
Children	5, including Isaac Henry Gosset
Scientific career	
Institutions	Guinness Brewery

William Sealy Gosset (1876-1937)

- Irish statistician
- Worked at Guinness brewery
- Published under pen name "Student"
- Developed t-distribution for small samples

なぜt分布が必要？

標本サイズが小さいとき、
正規分布は使えない

- Z分布：母集団の標準偏差 σ を知っているとき
- t分布：母集団の標準偏差 σ を知らないとき

t値の計算 p125

$$t = \frac{\bar{X} - \mu}{\sqrt{\hat{\sigma}_x^2 / n}}$$

- $\bar{X}$ は標本平均
- μ は母平均（帰無仮説の値）
- $\hat{\sigma}_x^2$ は標本不偏分散 ($\hat{\sigma}_x^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$)
- $\sqrt{\hat{\sigma}_x^2 / n}$ は標本平均の標準誤差 (= $s / \sqrt{n}$ 、ここで $s = \sqrt{\hat{\sigma}_x^2}$)
- n は標本サイズ

Now let's look at Steph Curry's example again. 🏀

95% 信頼区間 (DF = 4)

t分布表から DF=4 のとき、
95% CI の t値は **2.776**

つまり、帰無仮説を棄却する境界値は ± 2.776

α	0.10	0.05	0.01
DF=4	2.132	2.776	4.604
DF=5	2.015	2.571	4.032
DF=10	1.812	2.228	3.169
DF=30	1.697	2.042	2.750
DF= ∞	1.645	1.960	2.576

Z検定 vs t検定 : Steph Curryの例

Z検定 (Z-test)

- 母集団の標準偏差 σ を知っているとき
- 標本サイズが大きいとき ($n > 30$)

t検定 (t-test)

- 母集団の標準偏差 σ を知らないとき
- 標本サイズが小さいとき ($n < 30$) ← Steph Curryの例

Steph Curryのt値を計算

- 帰無仮説：Steph Curryのシーズン平均スコアは $\mu = 27.4$ ポイント
標本データ (過去5試合)： $\bar{X} = 28.6, \hat{\sigma}_x^2 = 353.3$

$$t = \frac{\bar{X} - \mu}{\sqrt{\hat{\sigma}_x^2/n}} = \frac{28.6 - 27.4}{\sqrt{353.3/5}}$$

$$t = \frac{1.2}{\sqrt{70.66}} = \frac{1.2}{8.41} = 0.143$$

結論

- 計算されたt値：0.143
- 自由度：4 ($n - 1 = 5 - 1$)
- 95% CI の臨界値： ± 2.776
- $0.143 < 2.776$ なので帰無仮説は棄却できない

帰無仮説 $H_0 : \mu = 27.4$

計算されたt値は0.143で、自由度4における95%信頼区間の臨界値 ± 2.776 より小さいため、帰無仮説は棄却できない。Steph Curryの真の平均スコアが27.4ではないとは統計的に言えない。

Now you try it!

もう一度、t値の公式を確認しよう：

$$t = \frac{\bar{X} - \mu}{\sqrt{\hat{\sigma}_x^2 / n}}$$

- $\bar{X}$ ：自分の選手の「過去5試合の平均スコア」
- μ ：シーズン平均スコア（仮定する母平均）
- $\hat{\sigma}_x^2$ ：さっき計算した標本不偏分散
- $n = 5$

自分の値を代入して、ノートに書こう：

- $\bar{X} = \underline{\hspace{2cm}}$

- $\mu = \underline{\hspace{2cm}}$

- $\hat{\sigma}_x^2 = \underline{\hspace{2cm}}$

- $t = \frac{\bar{X} - \mu}{\sqrt{\hat{\sigma}_x^2/5}} = \underline{\hspace{2cm}}$

t値からどう結論を出すか？

- この活動では、いつも $n = 5 \rightarrow$ 自由度 $df = 4$
- 95% 信頼水準（両側検定）の臨界値は ± 2.776

- $|t| > 2.776$ のとき

→ 帰無仮説 $H_0 : \mu = \text{シーズン平均}$ を棄却できる

- $|t| \leq 2.776$ のとき

→ 帰無仮説を棄却できない

ノートにまとめよう：

- 計算した t 値：_____
- 結論（日本語で一文）：

「この5試合の平均スコアは、シーズン平均と比べて統計的に（異なると言える／異なるとは言えない）。」

カイ二乗分布



Karl Pearson (1857-1936)

- English mathematician
- big boss of stats
- but... also one of the fathers of eugenics 「優生学」

「優生学」

“ Eugenics is the scientifically erroneous and immoral theory of “racial improvement” and “planned breeding,” which gained popularity during the early 20th century. Eugenicists worldwide believed that they could perfect human beings and eliminate so-called social ills through genetics and heredity. ”

優生学とは、20世紀初頭に人気を博した「人種改良」と「計画的繁殖」に関する科学的に誤った不道德な理論です。世界中の優生学者は、遺伝学と遺伝によって人間を完璧にし、いわゆる社会的悪を排除できると信じていました。

カイ二乗分布の定義


- χ^2 分布 (chi-squared distribution)
 - 自由度 ν のカイ二乗分布
 - 標準正規分布 $N(0,1)$ にしたがう独立な ν 個の確率変数 X_i の平方和に関する確率分布
 - $\chi^2(\nu) \quad X_1^2 + X_2^2 + X_3^2 + \dots + X_\nu^2$
 - 平均値 ν 自由度と等しい
 - 分散 2ν 自由度の2倍
 - 自由度が小さいとき左右非対称
 - 自由度が大きくなるにつれて左右対称に変化
 - 自由度の値が大きいつきに正規分布に近似

自由度 degree of freedom


$$n - 1$$

- 自由に動くことのできる変数の数
- 与えられた等式（条件）の分だけ減る
 - 例 データ（4, x, 1, 1） xは未知
条件 平均値は2
 $\Rightarrow 4+x+1+1=2 \times 4$
 - データの個数n個に
平均値を与える（条件1つ）と
データ **n-1**個がわかれば、すべてのデータがわかる
（残りの1つは必然的に決まる）

自由度10のカイ二乗分布



自由度10～50のカイ二乗分布



平方和の分解

Z^2 (標本平均 $\bar{X}$ を標準化した Z の平方)

– 自由度1のカイ二乗分布にしたがう

$$\frac{\sum (X_i - \mu_X)^2}{\sigma_X^2} = \frac{\sum (X_i - \bar{X})^2}{\sigma_X^2} + \frac{n(\bar{X} - \mu_X)^2}{\sigma_X^2}$$

自由度n
のカイ二乗分布

自由度n-1
のカイ二乗分布

自由度1
のカイ二乗分布

教科書ではわかりにくいので...

カイ二乗分析はなんで使うの？



現在の学生数

2,621名

男子：1,605名

女子：1,016名

(2024年5月現在)

60 : 40

 男子 : 女子 

本当かな？では、無作為で20人の学生を抽出したら...



11 : 9

本当かな？では、無作為で20人の学生を抽出したら...



12 : 8

本当かな？では、無作為で20人の学生を抽出したら...



13 : 7

本当かな？では、無作為で20人の学生を抽出したら...



14 : 6

本当かな？では、無作為で20人の学生を抽出したら...



15 : 5

なんとなく、直感（gut feeling）では解決できない...

カイ二乗検定

Chi Squared Test

集めたデータ ↔ 予測データ

H_0 帰無仮説 = 60 : 40

帰無仮説を棄却（ききやく）できるでしょうか？

Can we reject the null hypothesis?

In other words...

このクラスは、母集団（全校の比率）と比べて、有意に、
そして統計的に異なると言えるのか？

Is this class significantly, and statistically different from the population?

ではカイ二乗を求めよう：

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- χ^2 はカイ二乗検定統計量
- O_i はカテゴリ i の観測度数 (Observed)
- E_i はカテゴリ i の期待度数 (Expected)

自由度は？

$$n - 1$$

この場合の「 n 」はカテゴリーの数{男子,女子}が2なので自由度は1である


$$\text{Degree of Freedom (DF)} = 2 - 1 = 1$$

カイ二乗分布表

カイ二乗分布のパーセント点

カイ二乗分布表では、自由度 ν と上側確率 α に対応したカイ二乗分布 $\chi^2(\nu)$ のパーセント点 $\chi^2_{\alpha}(\nu)$ を表す。

たとえば、自由度 $\nu=5$ 、上側確率 $\alpha=0.025$ のとき、表側の 5 と表頭の 0.025 との交差点である 12.8325 が 2.5 パーセント点 $\chi^2_{0.025}(5)=12.8325$ となる。



ν	α	0.995	0.990	0.975	0.950	0.050	0.025	0.010	0.005
1		0.0000	0.0002	0.0010	0.0039	3.8415	5.0239	6.6349	7.8794
2		0.0100	0.0201	0.0506	0.1026	5.9915	7.3778	9.2103	10.5966
3		0.0717	0.1148	0.2158	0.3518	7.8147	9.3484	11.3449	12.8382
4		0.2070	0.2971	0.4844	0.7107	9.4877	11.1433	13.2767	14.8603
5		0.4117	0.5543	0.8312	1.1455	11.0705	12.8325	15.0863	16.7496
6		0.6757	0.8721	1.2373	1.6354	12.5916	14.4494	16.8119	18.5476
7		0.9893	1.2390	1.6899	2.1673	14.0671	16.0128	18.4753	20.2777
8		1.3444	1.6465	2.1797	2.7326	15.5073	17.5345	20.0902	21.9550
9		1.7349	2.0879	2.7004	3.3251	16.9190	19.0228	21.6660	23.5894
10		2.1559	2.5582	3.2470	3.9403	18.3070	20.4832	23.2093	25.1882

n=1

	O	E	O-E	(O-E) ²	(O-E) ² /E
男子	0	0	0	0	#DIV/0!
女子	0	0	0	0	#DIV/0!
	0			χ^2 (カイ二乗)→	#DIV/0!

Here



X^2

$> \cdot <$



確率 0.05 の値

従って、帰無仮説は棄却 できる・できない



コアラのマーチ「激レアキャラ」は都市伝説？

365種類の絵柄は全て同じ数だけ作ってると言われている。本当かな？

<https://www.lotte.co.jp/products/brand/koala/book/>

ご当地コアラ(51)

- 51種類

- 出る確率は $\frac{51}{365}$ or **14%**



スポーツコアラ(47)

- 47種類

- 出る確率は $\frac{47}{365}$ or **13%**



おあそび&おでかけ (29種類)

- 29種類
- 出る確率は $\frac{29}{365}$ or **8%**



お仕事 (28種類)

- 28種類
- 出る確率は $\frac{28}{365}$ or 8%



H_0 帰無仮説

コアラのご当地・スポーツ・仕事・おあそび&おでかけ・その他の比率
は

51 : 47 : 29 : 28 : 210

14% : 13% : 8% : 8% : 58%

である

帰無仮説を棄却できるでしょうか?

Can we reject the null hypothesis?

- 自由度(DF) : $5 - 1 = 4$

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

n=4

	Observed (O)	Expected (E)	O-E	(O-E) ²	(O-E) ² /E
ご当地コアラ (14%)	0	0	0	0	#DIV/0!
スポーツコアラ (13%)	0	0	0	0	#DIV/0!
仕事コアラ (8%)	0	0	0	0	#DIV/0!
おあそびコアラ (8%)	0	0	0	0	#DIV/0!
その他 (58%)	0	0	0	0	#DIV/0!
	0			χ ² (カイ二乗)→	#DIV/0!


Enter!

カイ二乗分布表

カイ二乗分布のパーセント点

カイ二乗分布表では、自由度 ν と上側確率 α に対応したカイ二乗分布 $\chi^2(\nu)$ のパーセント点 $\chi^2_{\alpha}(\nu)$ を表す。

たとえば、自由度 $\nu=5$ 、上側確率 $\alpha=0.025$ のとき、表側の 5 と表頭の 0.025 との交差点である 12.8325 が 2.5 パーセント点 $\chi^2_{0.025}(5)=12.8325$ となる。



ν	α	0.995	0.990	0.975	0.950	0.050	0.025	0.010	0.005
1		0.0000	0.0002	0.0010	0.0039	3.8415	5.0239	6.6349	7.8794
2		0.0100	0.0201	0.0506	0.1026	5.9915	7.3778	9.2103	10.5966
3		0.0717	0.1148	0.2158	0.3518	7.8147	9.3484	11.3449	12.8382
4		0.2070	0.2971	0.4844	0.7107	9.4877	11.1433	13.2767	14.8603
5		0.4117	0.5543	0.8312	1.1455	11.0705	12.8325	15.0863	16.7496
6		0.6757	0.8721	1.2373	1.6354	12.5916	14.4494	16.8119	18.5476
7		0.9893	1.2390	1.6899	2.1673	14.0671	16.0128	18.4753	20.2777
8		1.3444	1.6465	2.1797	2.7326	15.5073	17.5345	20.0902	21.9550
9		1.7349	2.0879	2.7004	3.3251	16.9190	19.0228	21.6660	23.5894
10		2.1559	2.5582	3.2470	3.9403	18.3070	20.4832	23.2093	25.1882