

統計学 #12

## 回帰分析の結果の解釈

- ◆ 第1章 第7節 回帰分析とその他の代表的な分析手法
  - ✓ Excelでの回帰分析を復習する
- ◆ 第2章 第4節 統計的仮説検定
  - ✓ 仮説検定の手順を復習する
- ◆ 第3章 第5節 分析結果の誤った解釈
  - ✓ 分析結果の誤った解釈の事例を理解する

## (復習) 回帰分析

思い出しながらExcelの分析ツールで改めて分析をしてみよう

## ■ 回帰分析 regression analysis


- ✓ 原因と結果（予測を行いたい変数）を分析者が設定し、その変数間の関係性を明らかにする統計的な分析手法

### ■ 目的変数：結果（ $y$ ）

- ✓ 予測を行いたい変数
- ✓ 分析の目的
- ✓ 被説明変数

### ■ 説明変数：原因（ $x$ ）

- ✓ 原因となり得る変数
- ✓ 独立変数




縦軸に結果，横軸に原因をとり  
散布図を描いていくイメージ

## ■ 仮説を立てる：

- ✓ 目的変数（結果）は，説明変数（原因）によって決まるのでは
  - アイスクリームへの消費額は，気温によって決まるのではないか
  - 気温は，アイスクリームへの消費額によって決まるのではないか（原因と結果が逆）は成り立たないことに注意

## ■ 式を立てる：

- ✓  $(\text{目的変数})_i = a + b(\text{説明変数})_i + u_i$
- ✓ 直線の関係式（1次関数）を立てて，切片  $a$  と傾き  $b$  を見つけることで，  
**2つの関係性を1次関数で表す**
  - $a$  と  $b$  の求め方：最小二乗法
  - $u_i$  ：誤差項（余り（誤差）．今回は無視．）



## 概要

| 回帰統計   |          |
|--------|----------|
| 重相関 R  | 0.935268 |
| 重決定 R2 | 0.874727 |
| 補正 R2  | 0.8622   |
| 標準誤差   | 152.4839 |
| 観測数    | 12       |

標本数 $n$ （データの数）

まずはここを確認.

今回は12か月のデータなので[12].

ここが合わない場合は,

[ラベル]の☑を忘れているか,  
データの選択範囲が間違っているので  
確認してみよう.

## 分散分析表

|    | 自由度 | 変動       | 分散       | 割り当てられた分散 | 有意 F     |
|----|-----|----------|----------|-----------|----------|
| 回帰 | 1   | 1623542  | 1623542  | 69.82571  | 8.02E-06 |
| 残差 | 10  | 232513.5 | 23251.35 |           |          |
| 合計 | 11  | 1856056  |          |           |          |

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

## 概要

| 回帰統計               |          |
|--------------------|----------|
| 重相関 R              | 0.935268 |
| 重決定 R <sup>2</sup> | 0.874727 |
| 補正 R <sup>2</sup>  | 0.8622   |
| 標準誤差               | 152.4839 |
| 観測数                | 12       |

決定係数 $R^2$   
 自由度修正済み決定係数Adj.  $R^2$   
 仮定した直線の関係式で、  
 どの程度データの関係性を説明できている  
 か。

$0 \leq R^2 \leq 1$   
 1に近いほど説明力が高い。

## 分散分析表

|    | 自由度 | 変動       | 分散       | 割り当てられた分散 | 有意 F     |
|----|-----|----------|----------|-----------|----------|
| 回帰 | 1   | 1623542  | 1623542  | 69.82571  | 8.02E-06 |
| 残差 | 10  | 232513.5 | 23251.35 |           |          |
| 合計 | 11  | 1856056  |          |           |          |

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |


## 概要

| 回帰統計   |          |
|--------|----------|
| 重相関 R  | 0.935268 |
| 重決定 R2 | 0.874727 |
| 補正 R2  | 0.8622   |
| 標準誤差   | 152.4839 |
| 観測数    | 12       |

## 分散分析表

|    | 自由度 | 変動    |
|----|-----|-------|
| 回帰 | 1   | 1623  |
| 残差 | 10  | 23251 |
| 合計 | 11  | 1856  |

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

 $a = 129.72$ 定数項 $a$  (切片)

これが切片の値.

今回は $a = 129.7238$


## 概要

| 回帰統計   |          |
|--------|----------|
| 重相関 R  | 0.935268 |
| 重決定 R2 | 0.874727 |
| 補正 R2  | 0.8622   |
| 標準誤差   | 152.4839 |
| 観測数    | 12       |

## 分散分析表

|    | 自由度 | 変動    |
|----|-----|-------|
| 回帰 | 1   | 1623  |
| 残差 | 10  | 23251 |
| 合計 | 11  | 1856  |

|        | 係数       | 標準誤差     | t値       | 確率 >  t  | 95.0%    | 95.0%    |
|--------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 152.4839 | 0.852    | 0.4148   | 0.0448   | 0.0448   |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 39.95904 |

回帰係数 $b$ （傾き）

1次関数の傾き。今回は $b = 47.33734$   
 原因（説明変数）が1単位増えたとき、  
 結果（目的変数）が何単位増えるか、を表す。  
 +なのか-なのかで  
 意味が真逆になるので注意（符号条件）

## 概要

| 回帰統計   |          |
|--------|----------|
| 重相関 R  | 0.935268 |
| 重決定 R2 | 0.874727 |
| 補正 R2  | 0.8622   |
| 標準誤差   | 152.4839 |
| 観測数    | 12       |

## 分散分析表

|    | 自由度 | 変動       |
|----|-----|----------|
| 回帰 | 1   | 1623542  |
| 残差 | 10  | 232513.5 |
| 合計 | 11  | 1856056  |

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

## p値

推定した係数の有意性を示す指標。  
現時点では、0.05よりも小さい値であれば、  
推定した係数 ( $b = 47.34$ ) に  
意味がある (有意) と考えればよい。  
切片  $a$  についても同様に見る。

回帰係数  $b = 0$  とする仮説 (帰無仮説) のもと  
で

検定統計量 (t値) を計算した場合、  
その絶対値以上の極端な値が出る確率。  
(詳細は授業の後半回でやります)

Excel上での表記

8.02E-06=0.00000802...

(※指数表示:  $8.02 \times 10^{-6}$ )

## (復習) 統計的仮説検定

## ■ 仮説検定の手順

- ✓ ① 検定方式の決定
- ✓ ② 仮説の設定
- ✓ ③ 有意水準（棄却域）の決定
- ✓ ④ データの収集
- ✓ ⑤ 棄却域の臨界値の計算
- ✓ ⑥ 検定統計量の計算
- ✓ ⑦ 判断

## ■ 帰無仮説 null hypothesis

✓  $H_0$

✓ 否定したい仮説（無に帰す）

➤ 例：男性の平均身長と女性の平均身長に差はない

➤  $H_0: \mu_M = \mu_F$

## ■ 対立仮説 alternative hypothesis

✓  $H_1$

✓ 分析者が立証したい仮説

➤ 例：男性の平均身長と女性の平均身長に差はない

➤  $H_0: \mu_M \neq \mu_F$

## ■有意水準 significance level

- ✓ 確率的に偶然とは考えにくく、意味があると考えられる水準
- ✓ 帰無仮説を棄却する基準となる確率
- ✓ 分析者が設定する
- ✓ 1%, 5%, 10%が一般的に使われることが多い
  - 学問分野による

## ■有意水準5%

- ✓ 5%以下の確率で起こる事象は  
100回中（平均的に）5回しか起こらない事象。  
極めて珍しいことが起こった、  
意味がある（＝有意である）とみなす。
- ✓ 棄却域の面積5%

## ■ 検定統計量 test statistics

- ✓ 標本データから計算される統計量
- ✓ この値と、⑤の臨界値を比較して、  
検定統計量の方が絶対値が大きければ、  
帰無仮説を棄却する。
- ✓ 「データに想定する分布」と「検定統計量のしたがう分布」を  
区別する必要があるため注意
- ✓ 例：t値（t分布の検定統計量）

$$\text{➤ } t = \frac{\bar{x} - \mu}{\sqrt{\frac{\widehat{\sigma^2}}{n}}} = \frac{(\text{標本平均}) - (\text{母平均})}{\sqrt{\frac{(\text{標本不偏分散})}{(\text{標本数})}}$$

## ■ 検定統計量が棄却域に含まれる


- ✓ 帰無仮説のもとでは、検定統計量の結果となることはほとんどない
- ✓ 帰無仮説を棄却して、**対立仮説を採用**

立証したい仮説が  
統計的に立証された！

## ■ 検定統計量が棄却域に含まれない

- ✓ 帰無仮説と対立仮説の**どちらが正しいかは不明**
- ✓ 帰無仮説が正しいかはわからないが、  
対立仮説が正しいとは言えない

間違っているとも言えない



## ■ p値 p-value

- ✓ 検定統計量に対応する確率
- ✓ 帰無仮説を棄却できるか否かを示す値
  - 差の大きさなどを示すものではないことに注意
- ✓ 例 :  $p = 0.035 < 0.05$ 
  - 有意水準5%で帰無仮説を棄却できる (有意水準1%ではできない)

## EXCELの分析結果の読み方

## 概要

| 回帰統計   |          |
|--------|----------|
| 重相関 R  | 0.935268 |
| 重決定 R2 | 0.874727 |
| 補正 R2  | 0.8622   |
| 標準誤差   | 152.4839 |
| 観測数    | 12       |

## 分散分析表

|    | 自由度 | 変動       | 分散       | 割り当てられた |
|----|-----|----------|----------|---------|
| 回帰 | 1   | 1623542  | 1623542  | 69.825  |
| 残差 | 10  | 232513.5 | 23251.35 |         |
| 合計 | 11  | 1856056  |          |         |

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

t値／p値

統計的仮説検定で学んだ  
母平均の検定（＝1群のt検定）  
をここで行っている

## ■ ①検定方式の決定

### ✓ 母平均の検定（1群t検定）

- 母平均（定数項 $a$ ／回帰係数 $b$ ）が0ではないことを検証するため
- 以下，回帰係数 $b$ に対するt検定を例とする

## ■ ②仮説の設定

### ✓ 帰無仮説： $H_0: b = 0$

- 回帰係数 $b$ は0である
  - 1次関数の傾きが0であるということは，水平線になる
  - 原因（x方向）が増えても，結果（y方向）が何も変わらない
  - 因果関係がない

### ✓ 対立仮説： $H_1: b \neq 0$

- 回帰係数 $b$ は0ではない

## ■ ③有意水準の設定

✓ 省略

## ■ ④データの収集

✓ 省略

## ■ ⑤棄却域の臨界値の計算

✓ 省略

## ■ ⑥検定統計量の計算


- ✓ 定義式に値を代入して, t値 (t-value) を計算する

$$\text{➤ } t = \frac{\bar{x} - \mu}{\sqrt{\frac{\hat{\sigma}^2}{n}}} = \frac{(\text{標本平均}) - (\text{母平均})}{\sqrt{\frac{(\text{標本不偏分散})}{(\text{標本数})}}$$

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

回帰係数**b**に関するt検定の  
t値

回帰係数**b**に関するt検定の  
p値



有意水準1%で統計的に有意 → 回帰係数 $b \neq 0$  → 傾きには意味がある

|        | 係数       | 標準誤差     | t        | P-値      | 下限 95%   | 上限 95%   | 下限 95.0% | 上限 95.0% |
|--------|----------|----------|----------|----------|----------|----------|----------|----------|
| 切片     | 129.7238 | 109.2037 | 1.187906 | 0.262318 | -113.597 | 373.0448 | -113.597 | 373.0448 |
| 月別平均気温 | 47.33734 | 5.664951 | 8.356178 | 8.02E-06 | 34.71504 | 59.95964 | 34.71504 | 59.95964 |

## CH3-5：分析結果の誤った解釈

# ①分散・標準偏差の解釈

25

✓ (pp. 189)

記述統計量は表1の通りである。表1より、体重のほうが分散の値が小さく、身長に比べてデータのばらつきは小さいことがわかる。

表 1. 記述統計量

|      | 身長     | 体重     |
|------|--------|--------|
| 平均値  | 150.3  | 50.0   |
| 分散   | 246.49 | 179.56 |
| 標準偏差 | 15.7   | 13.4   |

厚生労働省「国民健康・栄養調査」2018年度速報版 女性 総数

分散については、標準偏差より作成

✓ (pp. 189)

記述統計量は表1の通りである.

表1より, 体重のほうが分散の値が小さく,  
身長に比べてデータのばらつきは小さいことがわかる.

- 単位の違うデータ同士で, ばらつきを比較したい場合は,  
**変動係数**coefficient of variationを利用する

$$CV = \frac{\sigma}{\mu} = \frac{\text{標準偏差}}{\text{平均値}}$$

説明変数として使用した人口の推定係数は統計的に有意とはならず、目的変数である GDP と説明変数である人口は、因果関係がないことが明らかになった。

表 3. 推定結果

| 目的変数：GDP    | 回帰係数の推定値  | <i>p</i> 値 |
|-------------|-----------|------------|
| 定数項         | -20187.52 | 0.0001***  |
| 人口          | -29.18    | 0.248      |
| 自由度修正済み決定係数 |           | 0.87       |

註：表中の \*\*\* は有意水準 1% で統計的に有意であることを示す。

(pp. 190)

✓ (pp. 190)

説明変数として使用した人口の推定係数は  
統計的に有意とはならず、  
目的変数であるGDPと説明変数である人口は、  
因果関係がないことが明らかになった。

- 推定係数（推定した回帰係数）が有意でない場合、  
「統計的に因果関係があるかどうか**わからない**」だけで、  
「**因果関係がない**」とはいえない。

人口の増加が CO<sub>2</sub> 排出量に与える影響をみるために、以下の式を用いて回帰分析を行った。

$$(\text{人口}_i) = a + b(\text{CO}_{2i}) + \varepsilon_i$$

得た。ここから、人口が1単位増加すると、CO<sub>2</sub> 排出量が0.35単位増加することが明らかになった。

(pp. 191)

- ✓ (pp. 191)  
人口の増加がCO<sub>2</sub>排出量に与える影響を見るために、以下の式を用いて回帰分析を行った。
- ✓  $(人口_i) = a + b(CO2_i) + \varepsilon_i$
- ✓ 推定結果より、 $b = 0.35$ となり、有意水準5%で統計的に有意な結果を得た。ここから、人口が1単位増加すると、CO<sub>2</sub>排出量が0.35単位増加することが明らかになった。

■ 説明変数 $x$ （原因，右辺）が1単位増加すると，  
目的変数 $y$ （結果，左辺）が $b$ 単位増加する，と読む。

■ 因果関係は「原因→結果」の一方通行

- ✓ 例文の推定式から読めることは  
「CO<sub>2</sub>排出量が1単位増えると，人口が $b$ 単位増える」…？

自由度修正済み決定係数の値は  $-0.0012$  であり、モデルの当てはまりは非常に悪い。

(pp. 192)

✓ (pp. 192)

自由度修正済み決定係数の値は $-0.0012$ であり、  
モデルの当てはまりは非常に悪い。

- 説明変数の個数が多い（自由度が小さい）が、  
説明力（目的変数との関係性が薄い）場合。
- 「モデルの当てはまりは悪い」とする読み方は誤りではないが、  
分析モデルや変数選択、  
データの特徴を見直した方が良い。

サッカーの試合の勝敗（勝ちの場合に 1，それ以外の場合に 0 とする）に影響を与える要因を明らかにするため，最小二乗法（OLS）を用いて分析を行う。

(pp. 193)

✓ (pp. 193)

サッカーの試合の勝敗 (勝ち = 1, それ以外 = 0) に  
影響を与える要因を明らかにするため,  
最小二乗法(OLS)を用いて分析を行う.

- 目的変数がダミー変数である場合は,  
最小二乗法的前提条件を満たさないため,  
他の方法 (ロジット, プロビットなど) を用いることを検討する.
- 分析目的や使用データに**適した分析方法**を選択する.

## ■ 最小二乗法の推定量が不偏性をもつ条件

- ✓ ①説明変数 $x_i$ が確率変数ではない
- ✓ ②標本数 $n$ が大きくなるとき, 偏差平方和は無限大になる
- ✓ ③誤差項の期待値は0である
  - $E(u_i) = 0$
- ✓ ④誤差項の分散は一定である (均一分散性)
  - $Var(u_i) = \sigma^2$
- ✓ ⑤誤差項は互いに無相関である (独立性)
  - $Cov(u_i, u_j) = 0, i \neq j$

## ■ これらの条件を満たすモデルを古典的回帰モデルという

- ✓ 古典的回帰モデルで推定された推定量は最良である
  - ガウス・マルコフ定理

- 高血圧の人ほど年収が高い
- アイスクリームの売り上げが上がるほど、熱中症患者数が増える
- 少子化が進むと、温暖化が進む

(pp. 195)

- ✓ (pp. 195)
- ✓ 高血圧の人ほど年収が高い.
- ✓ アイスの売上が上がるほど、熱中症患者が増える.
- ✓ 少子化が進むと、温暖化が進む

- 相関係数の絶対値が大きいからといって、因果関係があるとはいえない.
- **相関関係と因果関係は別物**であることに注意.

- ✓ 相関関係：関係性がある
- ✓ 因果関係：原因と結果の関係

- <https://www.tylervigen.com/spurious-correlations>

✓ (pp. 196)

集落 A には 30 戸の農家がある。集落 A にある農家の年収について調査を行うため、30 戸すべての農家に年収に関する調査を行って回答を得た。このサンプルサイズ 30 のデータを用いて、年収の平均値に関する区間推定を行う。

✓ (pp. 196)

集落Aには30戸の農家がある.

集落Aにある農家の年収について調査を行うため,  
30戸すべての農家に年収に関する調査を行って回答を得た.  
このサンプルサイズ30のデータを用いて,  
年収の平均値に関する区間推定を行う.

■ 母集団のデータが手元にあるならば,  
そもそも推定作業は不要.

✓ 推定: 母集団の特徴が未知のとき,  
標本のデータから母集団を推測していく方法.

## ◆ 第1章 第7節 回帰分析とその他の代表的な分析手法

- ✓ Excelでの回帰分析を復習する

## ◆ 第2章 第4節 統計的仮説検定

- ✓ 仮説検定の手順を復習する
  - Excelの分析結果におけるt値／p値の読み方

## ◆ 第3章 第5節 分析結果の誤った解釈

- ✓ 分析結果の誤った解釈の事例を理解する