

統計学 #12

回帰分析とその他の代表的な分析手法 / 回帰分析の結果の解釈

◆第1章 第7節 回帰分析とその他の代表的な分析手法

- ✓ 相関関係と因果関係の違いを理解する
- ✓ 回帰分析について理解する
- ✓ Excel での単回帰分析を修得する

◆第2章 第4節 統計的仮説検定

- ✓ 仮説検定の手順を復習する

◆第3章 第5節 分析結果の誤った解釈

- ✓ 分析結果の誤った解釈の事例を理解する

1 : 変数間の関係性

相関関係


■ 2つの変数の間に
関係性があるか

- ✓ 散布図
- ✓ 相関係数

因果関係

■ 片方の変数が増えたとき、
もう片方の変数は
どの程度増えるか

- ✓ 回帰分析



相関関係があるからといって、因果関係があるとは限らない

2：回帰分析

■ 回帰分析 regression analysis


- ✓ 原因と結果（予測を行いたい変数）を分析者が設定し，その変数間の関係性を明らかにする統計的な分析手法

■ 目的変数：結果（ y ）

- ✓ 予測を行いたい変数
- ✓ 分析の目的
- ✓ 被説明変数

■ 説明変数：原因（ x ）

- ✓ 原因となり得る変数
- ✓ 独立変数




縦軸に結果，横軸に原因をとり
散布図を描いていくイメージ

■ 仮説を立てる：


- ✓ 目的変数（結果）は，説明変数（原因）によって決まるのでは
 - アイスクリームへの消費額は，気温によって決まるのではないか
 - 気温は，アイスクリームへの消費額によって決まるのではないか（原因と結果が逆）は成り立たないことに注意

■ 式を立てる：

- ✓ (目的変数) $_i = a + b(\text{説明変数})_i + u_i$
- ✓ 直線の関係式（1次関数）を立てて，切片 a と傾き b を見つけることで，**2つの関係性を1次関数で表す**
 - a と b の求め方：最小二乗法
 - u_i ：誤差項（余り（誤差）．今回は無視．）




(ADVANCED) 最小二乗法①




- ふたつのデータの散布図を描く
 - ✓ 横軸: X (原因)
 - ✓ 縦軸: Y (結果)
- 散布図に近似線を引く

(ADVANCED) 最小二乗法②



- ふたつのデータの散布図を描く
 - ✓ 横軸: X (原因)
 - ✓ 縦軸: Y (結果)
- 散布図に近似線を引く
- 近似線と各データ (点) のズレ (誤差) が最小になるような近似線の切片と傾きを求める
- 誤差は+も-もある得るため二乗して合計する (残差二乗和)
- 残差二乗和が最小になるように切片と傾きを決めるので **最小二乗法** という

EXCEL アドインを用いた回帰分析：下準備



- 演習用 Excel ファイルを開く
- [保護ビュー] の警告が出た場合は
[編集を有効にする] をクリック



- [データ] タブに [データ分析] ツールが表示されているか確認



- ✓ アイコンのみ表示されている場合もあり

[データ分析] ツールが表示されていない場合①


13



■ [ファイル] タブから [オプション] を選択

[データ分析] ツールが表示されていない場合②


14



- [オプション] 内の [アドイン] を表示
- [設定] をクリック

[データ分析] ツールが表示されていない場合③

15



- [分析ツール] に
☑を入れて [OK]

EXCEL アドインを用いた回帰分析：分析手順

月	アイスクリー	気温
	支出金額	月別平均気温
1月	550	5.7
2月	500	7.3
3月	665	12.9
4月	797	16.3
5月	1063	19
6月	1142	23.2
7月	1688	28.7
8月	1710	29.2
9月	1234	26.7
10月	823	18.9
11月	682	14.4
12月	724	9.4

■ 2023 年 1 月～12 月の
1 世帯あたりのアイスクリーム類への
支出金額（円）と
東京の月別平均気温（℃）

■ 月次の時系列データ

■ 仮説

- ✓ 気温が高い月ほど、
アイス類への支出金額は
増えるのではないかと
支出金額
- ✓ 目的変数（結果）→
気温
- ✓ 説明変数（原因）→

■ $(y: \text{目的変数})_i = a + b(x: \text{説明変数})_i + u_i$


✓ 今回の例では

$$(\text{支出金額})_i = a + b(\text{気温})_i + u_i$$

✓ 散布図を描いてデータを確認してみよう


➤ 横軸：原因

➤ 縦軸：結果




なんとなく
右肩上がり
になってい
そう…?

- [データ] タブから [データ分析] のアイコンをクリック



- [回帰分析] を選んで [OK]



■ [入力 Y 範囲] に，目的変数を選択

- ✓ [支出金額] の記述があるセルから， 724 （ 12 月の値）のセルまで

2023年1月から12月

月	アイスクリー 支出金額	気温 月別平均気温
1月	550	5.7
2月	500	7.3
3月	665	12.9
4月	797	16.3
5月	1063	19
6月	1142	23.2
7月	1688	28.7
8月	1710	29.2
9月	1234	26.7
10月	823	18.9
11月	682	14.4
12月	724	9.4

気温 気象庁「過去の気象データ検索」

回帰分析

入力元

入力 Y 範囲(Y): \$D\$6:\$D\$18

入力 X 範囲(X):

☐ ラベル(L) ☐ 定数に 0 を使用(Z)

☐ 有意水準(Q) 95 %

出力オプション

☐ 一覧の出力先(S):

☒ 新規ワークシート(P):

☐ 新規ブック(W)

残差

☐ 残差(R) ☐ 残差グラフの作成(D)

☐ 標準化された残差(I) ☐ 観測値グラフの作成(I)

正規確率

☐ 正規確率グラフの作成(N)

OK
キャンセル
ヘルプ(H)

■ [入力 X 範囲] に，説明変数を選択

✓ [月別平均気温] の記述があるセルから， 9.4 （ 12 月の値）
のセルまで

2023年1月から12月

月	アイスクリー 支出金額	気温 月別平均気温
1月	550	5.7
2月	500	7.3
3月	665	12.9
4月	797	16.3
5月	1063	19
6月	1142	23.2
7月	1688	28.7
8月	1710	29.2
9月	1234	26.7
10月	823	18.9
11月	682	14.4
12月	724	9.4

気温 気象庁「過去の気象データ」

回帰分析

入力元

入力 Y 範囲(Y): \$D\$6:\$D\$18

入力 X 範囲(X):

☐ ラベル(L) ☐ 定数に 0 を使用(Z) 95 %

☐ 有意水準(Q)

出力オプション

☐ 一覧の出力先(S):

☒ 新規ワークシート(P):

☐ 新規ブック(W)

残差

☐ 残差(R) ☐ 残差グラフの作成(D)

☐ 標準化された残差(I) ☐ 観測値グラフの作成(I)

正規確率

☐ 正規確率グラフの作成(N)

OK キャンセル ヘルプ(H)

- [ラベル] に ☒ (忘れやすいので注意!)
- [出力オプション] は結果の出力先 (お好みで)
 - ✓ ここまで出来たら [OK]

回帰分析

入力元

入力 Y 範囲(Y): \$D\$6:\$D\$18 ↑

入力 X 範囲(X): \$E\$6:\$E\$18 ↑

☒ ラベル(L) ☐ 定数に 0 を使用(Z)

☐ 有意水準(Q) 95 %

出力オプション

☒ 一覧の出力先(S): \$I\$14 ↑

☐ 新規ワークシート(P):

☐ 新規ブック(W)

残差

☐ 残差(R) ☐ 残差グラフの作成(D)

☐ 標準化された残差(I) ☐ 観測値グラフの作成(I)

正規確率

☐ 正規確率グラフの作成(N)

OK

キャンセル

ヘルプ(H)

EXCEL アドインを用いた回帰分析：結果の読み方

概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12

標本数 n (データの数)

まずはここを確認。
 今回は12か月のデータなので[12].
 ここが合わない場合は、
 [ラベル]の☑を忘れているか、
 データの選択範囲が間違っているので
 確認してみよう。

分散分析表

	自由度	変動	分散	割り当てられた分	有意 F
回帰	1	1623542	1623542	69.82571	8.02E-06
残差	10	232513.5	23251.35		
合計	11	1856056			

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12

決定係数 R^2
 自由度修正済み決定係数Adj. R^2
 仮定した直線の関係式で、
 どの程度データの関係性を説明できているか。

$$0 \leq R^2 \leq 1$$

1に近いほど説明力が高い。


分散分析表

	自由度	変動	分散	割り当てられた分散	有意 F
回帰	1	1623542	1623542	69.82571	8.02E-06
残差	10	232513.5	23251.35		
合計	11	1856056			

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12



分散分析表

	自由度	変動	分散	平方和	平方乗
回帰	1	1623542	1		
残差	10	232513.5	2		
合計	11	1856056			

定数項 a (切片)
これが切片の値。
今回は $a = 129.7238$

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964


概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12

分散分析表

	自由度	変動
回帰	1	1623542
残差	10	232513.5
合計	11	1856056

	係数	標準誤差
切片	129.7238	109.207
月別平均気温	47.33734	5.664951



回帰係数b(傾き)

1次関数の傾き. 今回は $b = 47.33734$
 原因(説明変数)が1単位増えたとき,
 結果(目的変数)が何単位増えるか, を表す.
 +なのか-なのかで
 意味が真逆になるので注意(符号条件)

95.0%

3.0448

59.95964

概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12

分散分析表

	自由度	変動	分散	りされ	有意 F
回帰	1	1623542	1623542	69.82571	8.02E-06
残差	10	232513.5	23251.35		
合計	11	1856056			

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

p値

推定した係数の有意性を示す指標。
現時点では、0.05よりも小さい値であれば、
推定した係数($b = 47.34$)に
意味がある(有意)と考えればよい。
切片 a についても同様に見る。

回帰係数 $b = 0$ とする仮説(帰無仮説)のもとで
検定統計量(t 値)を計算した場合、
その絶対値以上の極端な値が出る確率。
(詳細は授業の後半回でやります)

Excel上での表記

8.02E-06=0.00000802...
(※指数表示: 8.02×10^{-6})

■ 仮定した1次関数の式に当てはめて考える

✓ 今回の例では


$$(\text{支出金額})_i = a + b(\text{気温})_i + u_i$$

✓ 推定した結果

$$(\text{支出金額})_i = 129.72 + 47.34(\text{気温})_i$$

✓ ここからわかること

- 気温が1℃上がると、
アイスへの支出金額が
129.72円上がる



EXCEL の分析結果の読み方

概要

回帰統計	
重相関 R	0.935268
重決定 R2	0.874727
補正 R2	0.8622
標準誤差	152.4839
観測数	12

分散分析表

	自由度	変動	分散	りされた
回帰	1	1623542	1623542	69.825
残差	10	232513.5	23251.35	
合計	11	1856056		

t 値 / p 値
統計的仮説検定で学んだ
母平均の検定 (= 1 群の t 検
定)
をここで行っている

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

■ ①検定方式の決定

✓ 母平均の検定（1群t検定）

- 母平均（定数項 a ／回帰係数 b ）が0ではないことを検証するため
 - 以下，回帰係数 b に対するt検定を例とする

■ ②仮説の設定

✓ 帰無仮説： $H_0: b = 0$

- 回帰係数 b は0である
 - 1次関数の傾きが0であるということは，水平線になる
 - 原因（x方向）が増えても，結果（y方向）が何も変わらない
 - 因果関係がない

✓ 対立仮説： $H_1: b \neq 0$

- 回帰係数 b は0ではない

■ ③有意水準の設定

✓ 省略

■ ④データの収集

✓ 省略

■ ⑤棄却域の臨界値の計算

✓ 省略

■ ⑥検定統計量の計算


- ✓ 定義式に値を代入して, t値 (t-value) を計算する

$$\text{➤ } t = \frac{\bar{x} - \mu}{\sqrt{\frac{\hat{\sigma}^2}{n}}} = \frac{(\text{標本平均}) - (\text{母平均})}{\sqrt{\frac{(\text{標本不偏分散})}{(\text{標本数})}}$$

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

回帰係数*b*に関するt検定の
t値

回帰係数*b*に関するt検定の
p値



有意水準1%で統計的に有意 → 回帰係数 $b \neq 0$ → 傾きには意味がある

	係数	標準誤差	t	P-値	下限 95%	上限 95%	下限 95.0%	上限 95.0%
切片	129.7238	109.2037	1.187906	0.262318	-113.597	373.0448	-113.597	373.0448
月別平均気温	47.33734	5.664951	8.356178	8.02E-06	34.71504	59.95964	34.71504	59.95964

CH3- 5 : 分析結果の誤った解釈

■ ✓ (pp. 189)

記述統計量は表1の通りである.

表1より, 体重のほうが**分散の値が小さく**,
身長に比べてデータの**ばらつきは小さい**ことがわかる.

- 単位の違うデータ同士で, ばらつきを比較したい場合は,
変動係数coefficient of variationを利用する

$$CV = \frac{\sigma}{\mu} = \frac{\text{標準偏差}}{\text{平均値}}$$

✓ (pp. 190)

説明変数として使用した人口の推定係数は統計的に有意とはならず、目的変数である **GDP** と説明変数である人口は、**因果関係がない**ことが明らかになった。

- 推定係数（推定した回帰係数）が有意でない場合，「統計的に因果関係があるかどうかわからない」だけで，「因果関係がない」とはいえない。

- ✓ (pp. 191)
人口の増加がCO₂排出量に与える影響を見るために、以下の式を用いて回帰分析を行った。
 - ✓ $(人口_i) = a + b(CO2_i) + \varepsilon_i$
 - ✓ 推定結果より、 $b = 0.35$ となり、有意水準5%で統計的に有意な結果を得た。ここから、人口が1単位増加すると、CO₂排出量が0.35単位増加することが明らかになった。
- 説明変数（原因，右辺）が1単位増加すると，
目的変数（結果，左辺）が **b** 単位増加する，と読む。
- 因果関係は「原因→結果」の一方通行
 - ✓ 例文の推定式から読めることは
「CO₂排出量が1単位増えると，人口が **b** 単位増える」…？

④自由度修正済み決定係数がマイナス値

✓ (pp. 192)

自由度修正済み決定係数の値は -0.0012 であり、
モデルの当てはまりは非常に悪い。

- 説明変数の個数が多い（自由度が小さい）が、説明力（目的変数との関係性が薄い）場合。
- 「モデルの当てはまりは悪い」とする読み方は誤りではないが、分析モデルや変数選択、データの特徴を見直した方が良い。

✓ (pp. 193)

サッカーの試合の勝敗（勝ち = 1, それ以外 = 0）に影響を与える要因を明らかにするため、
最小二乗法を用いて分析を行う。

- 目的変数がダミー変数である場合は、
最小二乗法の前提条件を満たさないため、
他の方法（ロジット、プロビットなど）を用いることを検討する。
- 分析目的や使用データに適した分析方法を選択する。

■ 最小二乗法の推定量が不偏性をもつ条件

- ✓ ①説明変数 x_i が確率変数ではない
- ✓ ②標本数 n が大きくなるとき, 偏差平方和は無限大になる
- ✓ ③誤差項の期待値は0である
 - $E(u_i) = 0$
- ✓ ④誤差項の分散は一定である (均一分散性)
 - $Var(u_i) = \sigma^2$
- ✓ ⑤誤差項は互いに無相関である (独立性)
 - $Cov(u_i, u_j) = 0, i \neq j$

■ これらの条件を満たすモデルを古典的回帰モデルという

- ✓ 古典的回帰モデルで推定された推定量は最良である
 - ガウス・マルコフ定理

- ✓ (pp. 195)
- ✓ 高血圧の人ほど年収が高い.
- ✓ アイスの売上が上がるほど, 熱中症患者が増える.
- ✓ 少子化が進むと, 温暖化が進む

- 相関係数の絶対値が大きいかからといって, 因果関係があるとはいえない.
- 相関関係と因果関係は別物であることに注意.
 - ✓ 相関関係: 関係性がある
 - ✓ 因果関係: 原因と結果の関係

✓ (pp. 196)

集落 A には 30 戸の農家がある.

集落 A にある農家の年収について調査を行うため,
30 戸すべての農家に年収に関する調査を行って回答を得た.

このサンプルサイズ 30 のデータを用いて,
年収の平均値に関する区間推定を行う.

■ 母集団のデータが手元にあるならば,
そもそも推定作業は不要.

✓ 推定: 母集団の特徴が未知のとき,
標本のデータから母集団を推測していく方法.

◆第1章 第7節 回帰分析とその他の代表的な分析手法

✓ 相関関係と因果関係の違いを理解する

- 相関関係：関係性はあるか
- 因果関係：原因と結果の関係

✓ 回帰分析について理解する

- 回帰分析：原因と結果を分析者が設定し、その変数間の関係性を明らかにする分析手法
- 目的変数（結果, y ）
- 説明変数（原因, x ）

✓ Excelでの単回帰分析を修得する

- 決定係数：説明力を示す指標
- 定数項 a , 回帰係数 b
- p 値：係数の有意性を示す指標

◆第2章 第4節 統計的仮説検定

- ✓ 仮説検定の手順を復習する

- Excel の分析結果における t 値／p 値の読み方

◆第3章 第5節 分析結果の誤った解釈

- ✓ 分析結果の誤った解釈の事例を理解する